

Kuliah 09 - Pengenalan Machine Learning

Topik: Konsep Dasar, Tahapan, Evaluasi, dan Use Case

Pengampu: Yeni Herdiyeni, Program Studi Kecerdasan Buatan, SSMI-IPB University

Tanggal: 22 April 2026

Catatan: File asli berjudul `kuliah-09_pengenalan_machine_learning_slides.pdf`, namun di dalam slide tertulis “Kuliah 10”. Dokumen ini mengikuti konteks materi pengenalan machine learning.

1. Capaian Pembelajaran

Setelah mempelajari materi ini, mahasiswa diharapkan mampu:

1. Menjelaskan konsep *learning* dalam machine learning.
 2. Memahami tahapan utama dalam *workflow* machine learning.
 3. Menjelaskan mengapa model perlu dievaluasi.
 4. Membedakan **underfitting**, **overfitting**, dan model yang seimbang.
 5. Memahami use case regresi sebagai contoh penerapan machine learning.
-

2. Hubungan AI, Machine Learning, dan Data Science

Tiga bidang ini sering tumpang tindih, tetapi memiliki cakupan yang berbeda:

ARTIFICIAL INTELLIGENCE (AI)

- Bidang luas yang membangun sistem mampu meniru kecerdasan manusia.
- Contoh: *reasoning, planning, problem solving, perception*.

MACHINE LEARNING (ML)

- Subset dari AI yang berfokus pada sistem yang **belajar dari data**.
- Tidak diprogram secara eksplisit, tetapi menemukan pola dari data.
- Contoh: klasifikasi email spam, prediksi harga rumah, deteksi penyakit.

DATA SCIENCE

- Bidang yang berfokus pada pengolahan data untuk menghasilkan *insight*.

- Mencakup: pengumpulan data, pembersihan, analisis, dan visualisasi.
- Machine learning adalah salah satu *tools* dalam data science.

TINGKATAN DATA ANALYTICS

Tingkat	Pertanyaan Kunci	Contoh
Descriptive	Apa yang terjadi?	Produksi susu rata-rata 20 liter/hari
Diagnostic	Mengapa ini terjadi?	Mengapa hasil panen menurun?
Predictive	Apa yang akan terjadi?	Prediksi hasil panen musim depan
Prescriptive	Apa yang sebaiknya dilakukan?	Waktu tanam optimal

3. Mengapa Kita Perlu Machine Learning?

USE CASE: PREDIKSI PRODUKSI TANAMAN

Input:

- Curah hujan
- Suhu
- Kelembaban tanah
- Jenis tanah
- Pupuk

Output: Hasil panen (ton/ha)

Pendekatan Tradisional

- Sulit membuat aturan pasti karena banyak faktor saling berinteraksi.
- Bersifat subjektif dan tidak konsisten antar pengamat.

Pendekatan Machine Learning

- Belajar dari data historis.
- Menangkap pola kompleks dan non-linear.
- Prediksi lebih akurat dan dapat diskalakan.

DEFINISI MACHINE LEARNING

Machine learning adalah pendekatan dalam kecerdasan buatan yang memungkinkan sistem belajar dari data untuk menemukan pola dan menghasilkan prediksi atau keputusan.

Ide utama:

- Kita tidak menulis semua aturan secara eksplisit.
 - Sistem belajar hubungan antara input dan output dari contoh data.
 - Hasil belajar direpresentasikan dalam bentuk **model**.
-

4. Konsep Learning dalam Machine Learning

LEARNING = DATA + MODEL + PENYESUAIAN PARAMETER

Komponen utama:

- **Input X** : fitur yang diamati.
- **Target y** : nilai sebenarnya.
- **Model f** : pemetaan $X \rightarrow y$.
- **Loss/Error**: ukuran kesalahan prediksi.

$$\hat{y} = f(X)$$

Proses learning:

1. Model menerima data training.
2. Menghasilkan prediksi $\hat{y}$.
3. Membandingkan prediksi dengan nilai sebenarnya y .
4. Menghitung error.
5. Menyesuaikan parameter model untuk meminimalkan error.

$$\text{Error} = y - \hat{y}$$

PERBANDINGAN: PEMROGRAMAN TRADISIONAL VS MACHINE LEARNING

Aspek	Pemrograman Tradisional	Machine Learning
Input	Data + aturan eksplisit	Data + contoh output
Proses	Programmer menulis aturan	Sistem belajar pola sendiri
Output	Hasil dari aturan	Prediksi/keputusan dari model
Cocok untuk	Aturan yang jelas dan stabil	Aturan yang sulit ditulis manual

Contoh cocok untuk ML: prediksi harga rumah, deteksi penyakit, prediksi hasil panen, prediksi curah hujan.

5. Jenis-Jenis Learning

5.1 SUPERVISED LEARNING (PEMBELAJARAN TERBIMBING)

Konsep: Belajar dari data yang memiliki label/target.

$$((X, y) \rightarrow \text{Model} \rightarrow \hat{y})$$

Tujuan: Melakukan prediksi terhadap data baru.

Contoh:

- Prediksi harga rumah.
- Klasifikasi email spam.
- Prediksi hasil panen.

5.2 UNSUPERVISED LEARNING (PEMBELAJARAN TAK TERBIMBING)

Konsep: Belajar dari data tanpa label untuk menemukan pola tersembunyi.

$$X \rightarrow \text{Model} \rightarrow \text{Pola / Cluster}$$

Tujuan: Mengelompokkan atau menyederhanakan data.

Contoh:

- Segmentasi pelanggan.
- Pengelompokan wilayah pertanian.
- *Dimensionality reduction*.

5.3 REINFORCEMENT LEARNING (PEMBELAJARAN PENGUATAN)

Konsep: Belajar melalui interaksi dengan lingkungan, menggunakan aksi dan *reward*.

Komponen:

- **Agent:** pengambil keputusan.
- **Environment:** lingkungan tempat agent berinteraksi.
- **Reward:** umpan balik dari setiap aksi.

Contoh:

- Robot navigasi.
- Sistem rekomendasi adaptif.
- Game playing (AlphaGo, DQN).

6. Use Case Machine Learning dalam Kehidupan Nyata

Domain	Aplikasi
Pendidikan	Prediksi mahasiswa berisiko terlambat lulus
Kesehatan	Prediksi kemungkinan penyakit dari hasil pemeriksaan
Pertanian	Prediksi hasil panen berdasarkan cuaca dan pupuk
Kelautan	Prediksi wilayah potensi penangkapan ikan dari data oseanografi
Bisnis	Rekomendasi produk dan prediksi churn pelanggan

7. Tahapan Machine Learning

7.1 RINGKASAN TAHAPAN

1. Menentukan masalah dan tujuan

2. Mengumpulkan data
3. Pra-pemrosesan data
4. Membagi data: training, validation, testing
5. Melatih model
6. Mengevaluasi model
7. Memilih model terbaik
8. Deployment dan monitoring

7.2 TAHAPAN 1: PROBLEM FORMULATION DAN DATA PREPARATION

Problem formulation:

- Apa yang ingin diprediksi?
- Apakah masalahnya regresi atau klasifikasi?
- Apa metrik keberhasilannya?

Data preparation:

- Membersihkan *missing values* dan *noise*.
- Memilih fitur yang relevan (*feature selection*).
- Melakukan encoding/normalisasi jika diperlukan.

7.3 TAHAPAN 2: TRAINING, VALIDATION, DAN TESTING

Subset	Fungsi	Proporsi Umum
Training set	Melatih model dan menyesuaikan parameter	60-80%
Validation set	Memilih model atau hyperparameter terbaik	10-20%
Test set	Menilai performa akhir pada data baru	10-20%

Intuisi: training untuk belajar, validation untuk memilih, testing untuk menguji secara final.

7.4 TAHAPAN 3: DEPLOYMENT DAN MONITORING

Deployment berarti model digunakan pada lingkungan nyata.

Contoh deployment:

- Sistem prediksi harga komoditas di dashboard.

- Model prediksi risiko pasien di rumah sakit.
- Sistem rekomendasi lokasi tanam untuk petani.

Monitoring diperlukan karena:

- Data baru bisa berubah pola (*concept drift*).
- Performa model bisa menurun seiring waktu.
- Model perlu diperbarui secara berkala.

8. Mengapa Model Harus Dievaluasi?

Model yang terlihat bagus pada data training belum tentu bagus pada data baru. Evaluasi model bertujuan untuk:

1. Mengukur kualitas prediksi.
2. Membandingkan beberapa model.
3. Mendeteksi underfitting atau overfitting.
4. Memastikan model layak digunakan.

8.1 EVALUASI PADA REGRESI

Metrik	Rumus	Interpretasi
MAE	$\frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i $	Rata-rata kesalahan absolut
MSE	$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	Rata-rata kesalahan kuadrat, memberi penalti lebih besar pada error besar
RMSE	$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$	Error dalam satuan asli target
R^2	$1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$	Proporsi variansi data yang dijelaskan model

Intuisi umum:

- Error kecil menjadi prediksi lebih baik.
- R^2 besar menjadi model menjelaskan variasi data lebih baik.

8.2 EVALUASI PADA KLASIFIKASI

Metrik	Definisi
Akurasi	Proporsi prediksi benar secara keseluruhan
Precision	Dari yang diprediksi positif, berapa yang benar-benar positif
Recall	Dari yang benar-benar positif, berapa yang berhasil ditemukan
F1-score	Rata-rata harmonik precision dan recall
Confusion Matrix	Tabel perbandingan prediksi vs aktual per kelas

Contoh: pada deteksi penyakit, **recall** sering penting agar kasus positif tidak banyak terlewat.

8.3 USE CASE EVALUASI DI DUNIA NYATA

Kasus	Metrik yang Cocok
Prediksi hasil panen	MAE, RMSE
Deteksi tanaman sakit vs sehat	Precision, Recall, F1-score
Prediksi wilayah penangkapan ikan	Error prediksi, akurasi klasifikasi, atau metrik spasial

9. Underfitting, Overfitting, dan Model Seimbang

9.1 UNDERFITTING

Ciri-ciri:

- Model terlalu sederhana.
- Tidak mampu menangkap pola penting.
- Error training dan testing sama-sama tinggi.

Contoh: menggunakan model linear sederhana untuk data yang pola hubungannya sangat non-linear.

9.2 OVERFITTING

Ciri-ciri:

- Model terlalu kompleks.
- Sangat baik pada training set.
- Buruk pada validation atau test set.

Penyebab umum:

- Terlalu banyak parameter.
- Data training terlalu sedikit.
- Model menangkap *noise* sebagai pola.

9.3 BALANCED MODEL (MODEL SEIMBANG)

Ciri-ciri:

- Cukup kompleks untuk menangkap pola utama.
- Tidak terlalu sensitif terhadap noise.
- Performa training dan testing sama-sama baik.

Tujuan utama ML: menemukan model yang seimbang antara akurasi dan generalisasi.

9.4 TABEL PERBANDINGAN

Kondisi	Kompleksitas	Train Error	Test Error
Underfitting	Rendah	Tinggi	Tinggi
Balanced	Sedang	Rendah	Rendah
Overfitting	Tinggi	Sangat rendah	Tinggi

9.5 CARA MEMILIH MODEL

1. Mulai dari model sederhana.
2. Evaluasi dengan validation set.
3. Bandingkan beberapa model dan parameter.
4. Pilih model terbaik pada data validasi, bukan hanya training.
5. Gunakan test set hanya untuk evaluasi akhir.

10. Contoh Penerapan: Regresi untuk Prediksi Hasil Panen Padi

10.1 TUJUAN REGRESI

Regresi bertujuan memprediksi nilai numerik atau kontinu.

Contoh target regresi:

- Harga rumah
- Suhu udara
- Hasil panen
- Jumlah produksi ikan

10.2 USE CASE: PREDIKSI HASIL PANEN PADI

Misalkan kita ingin memprediksi hasil panen padi (ton/ha) berdasarkan fitur:

- Curah hujan (mm)
- Suhu rata-rata (derajat C)
- Kelembaban tanah (%)
- Penggunaan pupuk (kg/ha)

Masalah ini adalah **supervised learning jenis regresi** karena target yang diprediksi berupa nilai kontinu.

10.3 REPRESENTASI DATA

Setiap baris data memiliki:

- **Fitur (\$X\$):** curah hujan, suhu, kelembaban tanah, pupuk, luas lahan.
- **Target (\$y\$):** hasil panen (ton/ha).

10.4 PEMBAGIAN DATA

Subset	Proporsi	Fungsi
Training	60%	Melatih model
Validation	20%	Memilih model dan hyperparameter
Testing	20%	Evaluasi performa akhir

10.5 MODEL REGRESI

Model mencoba memetakan fitur ke hasil panen:

$$\hat{y} = f(X)$$

Contoh model linear:

$$\hat{y} = w_1 \cdot \text{curah hujan} + w_2 \cdot \text{suhu} + w_3 \cdot \text{kelembaban tanah} + w_4 \cdot \text{pupuk}$$

Model memiliki parameter w yang dipelajari dari data training.

10.6 PERHITUNGAN METRIK (CONTOH NUMERIK)

Data:

- Aktual: $[6.0, 5.0]$ ton/ha
- Prediksi: $[5.5, 3.0]$

Error:

- $e_1 = 6.0 - 5.5 = 0.5$
- $e_2 = 5.0 - 3.0 = 2.0$

MAE:

$$\text{MAE} = \frac{|0.5| + |2.0|}{2} = 1.25$$

MSE:

$$\text{MSE} = \frac{0.5^2 + 2.0^2}{2} = \frac{0.25 + 4}{2} = 2.125$$

RMSE:

$$\text{RMSE} = \sqrt{2.125} \approx 1.46$$

MAPE:

$$\text{MAPE} = \frac{1}{2} \left(\frac{0.5}{6.0} + \frac{2.0}{5.0} \right) \times 100\% \approx 24.2\%$$

10.7 INTERPRETASI METRIK DALAM KONTEKS PERTANIAN

Metrik	Nilai	Makna
MAE	1.25 ton/ha	Rata-rata kesalahan prediksi
RMSE	1.46 ton/ha	Error dalam satuan asli, lebih mudah dipahami
MAPE	24.2%	Persentase error, mudah dikomunikasikan ke petani
R^2	-	Seberapa baik model mengikuti pola data

10.8 PREDIKSI UNTUK DATA BARU

Setelah model dilatih dan dievaluasi, kita dapat memprediksi hasil panen untuk lahan baru:

Contoh input baru:

- Curah hujan = 220 mm
- Suhu = 28 derajat C
- Kelembaban tanah = 68%
- Pupuk = 260 kg/ha

$$\hat{y} = f(X_{\text{baru}})$$

Manfaat:

- Perencanaan budidaya.
- Estimasi produktivitas lahan.

11. Alur Berpikir pada Use Case Regresi

1. Tentukan target: hasil panen.
2. Kumpulkan data historis.
3. Bagi data menjadi training, validation, testing.
4. Latih model regresi.
5. Evaluasi error prediksi.
6. Pilih model terbaik.
7. Gunakan model untuk prediksi musim berikutnya.

12. Ringkasan

1. **Machine learning** adalah proses belajar dari data untuk membangun model.
2. **Workflow ML** mencakup problem formulation, data collection, preprocessing, training, validation, testing, dan deployment.
3. **Evaluasi model** penting untuk memastikan generalisasi, bukan hanya akurasi training.
4. **Pemilihan model** harus mempertimbangkan underfitting, overfitting, dan keseimbangan.
5. **Regresi** adalah contoh supervised learning untuk memprediksi nilai kontinu.
6. Metrik seperti MAE, MSE, RMSE, dan R^2 membantu mengukur kualitas model regresi.
7. Machine learning sangat berguna ketika pola data sulit dirumuskan dengan aturan manual.