

Kuliah 11 - Shrinkage Methods dalam Sains Data

Topik: Ridge dan Lasso Regression

Mata Kuliah: Pengantar Sains Data

Pengampu: Yeni Herdiyeni, Program Studi Sarjana Kecerdasan Buatan, IPB University

1. Alur Pembahasan

Materi ini dibahas secara bertahap melalui lima langkah utama:

1. Memahami use case prediksi hasil panen padi.
 2. Mengetahui **OLS** sebagai model dasar regresi linear.
 3. Melihat permasalahan OLS pada data dengan fitur yang saling berkorelasi.
 4. Memahami bagaimana **Ridge** mengatasi masalah tersebut dengan menyusutkan semua koefisien.
 5. Memahami bagaimana **Lasso** menyusutkan koefisien sekaligus melakukan seleksi fitur.
-

2. Use Case: Prediksi Hasil Panen Padi

2.1 KASUS

Kita ingin memprediksi hasil panen padi berdasarkan sejumlah variabel lingkungan dan budidaya.

Contoh fitur yang digunakan:

Fitur	Keterangan
rainfall	Curah hujan
humidity	Kelembapan udara
temperature	Temperatur
soil_moisture	Kelembapan tanah
irrigation	Irigasi
fertilizer_A	Pupuk A
fertilizer_B	Pupuk B
sunlight	Cahaya matahari
soil_ph	pH tanah
pest_index	Indeks hama

2.2 TUJUAN

Membangun model yang dapat memperkirakan hasil panen berdasarkan kombinasi seluruh variabel tersebut.

2.3 MENGAPA KASUS INI MENARIK?

Faktor-faktor yang memengaruhi hasil panen biasanya tidak berdiri sendiri. Banyak variabel bergerak bersama dan saling berhubungan:

- Saat curah hujan meningkat, kelembapan tanah sering ikut meningkat.
- Temperatur dapat berhubungan dengan kelembapan udara.
- Pupuk A dan pupuk B dapat memiliki pola penggunaan yang mirip.

Akibatnya: Model menjadi lebih sulit membedakan mana pengaruh murni dari tiap variabel. Di sinilah persoalan **multikolinearitas** mulai muncul.

3. Apa Itu OLS?

3.1 ORDINARY LEAST SQUARES (OLS)

OLS adalah metode regresi linear yang mencari model terbaik dengan cara meminimalkan jumlah kuadrat error antara nilai aktual dan nilai prediksi:

$$\min_{\beta} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Di mana:

- y_i : hasil panen aktual.
- $\hat{y}_i$: hasil panen yang diprediksi model.

3.2 MODEL OLS PADA USE CASE

$$\text{yield} = \beta_0 + \beta_1(\text{rainfall}) + \beta_2(\text{temperature}) + \dots + \beta_p(\text{pest index})$$

Koefisien β_j menunjukkan seberapa besar kontribusi masing-masing fitur terhadap hasil panen.

3.3 CARA MEMBACA OLS

- OLS mencoba menarik satu hubungan linear terbaik dari data.
- Jika koefisien suatu fitur **positif**, kenaikan fitur tersebut cenderung meningkatkan prediksi hasil panen.
- Jika koefisien **negatif**, kenaikan fitur tersebut cenderung menurunkan prediksi hasil panen.

3.4 KEKUATAN OLS

- **Sederhana** dan mudah dijelaskan.
 - **Cepat** dihitung.
 - Cocok sebagai **model awal atau baseline**.
-

4. Permasalahan OLS: Multikolinearitas

4.1 APA ITU MULTIKOLINEARITAS?

Multikolinearitas adalah kondisi di mana beberapa prediktor (fitur) saling berhubungan secara linear. Pada data hasil panen, banyak prediktor saling berhubungan.

4.2 DAMPAK MULTIKOLINEARITAS PADA OLS

Koefisien OLS dapat berubah cukup besar ketika data sedikit berubah. Hal ini menunjukkan bahwa model memang bisa *fit* pada data latih, tetapi belum tentu **stabil** untuk interpretasi dan prediksi baru.

Makna visualisasi: Setiap box dalam plot koefisien menunjukkan variasi koefisien dari banyak sampel ulang. Semakin lebar variasinya, semakin tidak stabil estimasi koefisien OLS.

4.3 MENGAPA PERLU SHRINKAGE?

Ide utamanya sederhana:

- OLS hanya fokus mengecilkan error.
- OLS tidak menahan koefisien agar tetap kecil.
- Pada data yang kompleks, model bisa menjadi terlalu “percaya diri.”

Shrinkage hadir untuk:

1. Tetap meminimalkan error prediksi.
2. Sekaligus menambahkan penalti pada besar koefisien.
3. Membuat model lebih stabil dan lebih baik dalam generalisasi.

5. Ridge Regression

5.1 GAGASAN UTAMA RIDGE

Ridge menggunakan OLS sebagai dasar, lalu menambahkan penalti terhadap **kuadrat koefisien**. Dengan demikian, semua koefisien didorong untuk mengecil.

5.2 FUNGSI OBJEKTIF RIDGE

$$\min_{\beta_0, \beta} \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

Di mana:

- $\lambda \geq 0$ adalah parameter penalti (regularization strength).
- $\sum_{j=1}^p \beta_j^2$ adalah penalti L_2 .

5.3 PENGARUH NILAI λ

Nilai λ	Efek
$\lambda = 0$	Ridge sama seperti OLS
λ membesar	Penalti makin kuat
λ sangat besar	Semua koefisien mendekati nol, tetapi umumnya tidak tepat nol

5.4 INTUISI RIDGE PADA KASUS HASIL PANEN

Mengapa Ridge membantu?

- Saat beberapa fitur sama-sama relevan, tetapi saling berkorelasi.
- Ridge membagi pengaruh secara lebih hati-hati di antara fitur-fitur tersebut.

Pesan sederhana: Ridge berkata, “Semua fitur boleh tetap masuk, tetapi jangan ada koefisien yang terlalu ekstrem.”

5.5 KARAKTERISTIK RIDGE

- Menyusutkan semua koefisien secara bersamaan.
- Tidak melakukan seleksi fitur (koefisien tidak menjadi tepat nol).
- Sangat efektif untuk menangani multikolinearitas.
- Meningkatkan stabilitas prediksi.

6. Lasso Regression

6.1 GAGASAN UTAMA LASSO

Lasso juga berangkat dari OLS, tetapi penalti yang digunakan adalah **jumlah nilai absolut koefisien**. Penalty ini membuat sebagian koefisien dapat menjadi tepat nol.

6.2 FUNGSI OBJEKTIF LASSO

$$\min_{\beta_0, \beta} \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

Di mana:

- $\lambda \geq 0$ adalah parameter penalti.

- $\sum_{j=1}^p |\beta_j|$ adalah penalti L_1 .

6.3 PENGARUH NILAI λ

Nilai λ	Efek
λ kecil	Hampir sama seperti OLS
λ membesar	Beberapa koefisien menyusut kuat sampai nol
λ sangat besar	Hanya sedikit fitur yang tersisa

6.4 INTUISI LASSO PADA KASUS HASIL PANEN

Mengapa Lasso menarik?

- Tidak semua fitur selalu penting.
- Beberapa fitur mungkin hanya memberi kontribusi kecil.
- Lasso membantu memilih fitur yang paling dominan.

Pesan sederhana: Lasso berkata, “Jika suatu fitur tidak cukup penting, lebih baik koefisiennya dibuat nol.”

6.5 EFEK SELEKSI FITUR PADA LASSO

Semakin besar penalti λ , semakin banyak fitur yang dieliminasi dari model. Karena itu, Lasso sangat berguna saat kita juga ingin **menyederhanakan model**, bukan hanya meningkatkan kestabilan.

7. Perbandingan OLS, Ridge, dan Lasso

Aspek	OLS	Ridge	Lasso
Fungsi tujuan	Minimalkan SSE	$SSE + \lambda \sum \beta_j^2$	$SSE + \lambda \sum \beta_j $
Penalti	Tidak ada	L_2	L_1
Koefisien	Tidak dibatasi	Menyusut, tapi tidak nol	Bisa menjadi tepat nol
Seleksi fitur	Tidak	Tidak	Ya
Multikolinearitas	Rentan	Tangguh	Tangguh
Kompleksitas model	Penuh	Penuh	Lebih ringkas

VISUALISASI EFEK PENALTI

- **OLS:** koefisien bebas bergerak untuk meminimalkan error.
- **Ridge:** semua koefisien menyusut bertahap ketika λ membesar.
- **Lasso:** beberapa koefisien menjadi nol ketika λ diperbesar.

8. Kapan Menggunakan Ridge dan Kapan Lasso?

GUNAKAN RIDGE JIKA...

- Banyak fitur sama-sama penting.
- Terdapat multikolinearitas.
- Fokus utamanya adalah kestabilan dan akurasi prediksi.
- Anda ingin mempertahankan semua fitur dalam model.

GUNAKAN LASSO JIKA...

- Ingin model yang lebih ringkas.
- Ingin seleksi fitur otomatis.
- Diduga hanya sebagian kecil fitur yang dominan.
- Interpretasi model yang sederhana sangat penting.

KOMBINASI: ELASTIC NET

Dalam praktik, sering digunakan **Elastic Net** yang menggabungkan penalti L_1 dan L_2 :

$$\min_{\beta} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda_1 \sum_{j=1}^p |\beta_j| + \lambda_2 \sum_{j=1}^p \beta_j^2$$

Elastic Net memberikan keuntungan baik Ridge (stabil terhadap multikolinearitas) maupun Lasso (seleksi fitur).

9. Implementasi Python

9.1 RIDGE REGRESSION

```
from sklearn.linear_model import Ridge
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import make_pipeline

# Ridge dengan alpha = lambda
ridge_model = make_pipeline(
    StandardScaler(),
    Ridge(alpha=1.0)
)

ridge_model.fit(X_train, y_train)
y_pred_ridge = ridge_model.predict(X_test)
```

9.2 LASSO REGRESSION

```
from sklearn.linear_model import Lasso
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import make_pipeline

# Lasso dengan alpha = lambda
lasso_model = make_pipeline(
    StandardScaler(),
    Lasso(alpha=0.1)
)

lasso_model.fit(X_train, y_train)
y_pred_lasso = lasso_model.predict(X_test)
```


Catatan: Standardisasi fitur sangat penting sebelum menerapkan Ridge atau Lasso karena penalti sensitif terhadap skala fitur.

10. Interpretasi Hasil dalam Konteks Pertanian

10.1 RIDGE: SEMUA FAKTOR DIPERTIMBANGKAN

Dalam prediksi hasil panen, Ridge cocok ketika kita percaya bahwa banyak variabel lingkungan dan budidaya secara kolektif memengaruhi hasil panen, meskipun beberapa di antaranya saling berkorelasi.

10.2 LASSO: MEMILIH FAKTOR KUNCI

Lasso cocok ketika kita ingin menyederhanakan model dan hanya menyimpan faktor-faktor yang paling berpengaruh. Misalnya, dari 10 fitur, mungkin hanya 4 atau 5 yang benar-benar dominan dalam memprediksi hasil panen.

10.3 KALIMAT PENUTUP

Pada masalah prediksi hasil panen, **Ridge** membantu ketika banyak variabel sama-sama relevan, sedangkan **Lasso** membantu ketika kita juga ingin mengetahui fitur mana yang benar-benar penting.

11. Ringkasan

1. **OLS** adalah dasar regresi linear yang meminimalkan jumlah kuadrat error.
2. **Multikolinearitas** dapat membuat koefisien OLS tidak stabil.
3. **Ridge Regression** menambahkan penalti L_2 untuk menyusutkan semua koefisien dan mengatasi multikolinearitas.
4. **Lasso Regression** menambahkan penalti L_1 untuk menyusutkan koefisien dan melakukan seleksi fitur otomatis.
5. Gunakan **Ridge** jika banyak fitur sama-sama penting dan ada multikolinearitas.
6. Gunakan **Lasso** jika ingin model yang lebih ringkas dan dapat diinterpretasikan.
7. **Standardisasi fitur** wajib dilakukan sebelum menerapkan Ridge atau Lasso.
8. **Elastic Net** menggabungkan keunggulan kedua metode.