


Kuliah 08 - Metode Regresi Nonlinear

Regresi Polynomial, Fungsi Tangga, dan Basis Function

Yeni Herdiyeni
Program Studi Kecerdasan Buatan
IPB University



Fokus utama: bagaimana membuat model tetap linear pada parameter, tetapi lebih fleksibel terhadap bentuk hubungan $x \mapsto y$.

Ide besar: nonlinear dalam variabel, tetap terstruktur dalam model

Bentuk umum

$$\hat{y}(x) = \beta_0 + \sum_{m=1}^M \beta_m h_m(x)$$


- Kita tidak langsung memodelkan garis lurus pada x .
- Kita terlebih dahulu mengubah x menjadi sekumpulan fitur baru $h_1(x), h_2(x), \dots, h_M(x)$.
- Setelah itu, regresi dilakukan secara linear pada fitur hasil transformasi tersebut.

Filosofi utama

Hubungan dapat dibuat fleksibel dengan memilih *bahasa representasi* yang tepat untuk x : global, lokal, halus, atau bertingkat.

Tiga keluarga penting

- ➊ **Polynomial regression**
Memakai pangkat $x, x^2, x^3, \dots$
- ➋ **Step function regression**
Memakai indikator interval
- ➌ **Basis function regression**
Memakai basis umum: spline, RBF, Fourier, dst.



Use Case 1: Pertanian — Regresi Polynomial

Contoh kasus

Memprediksi **hasil panen** berdasarkan:

- dosis pupuk,
- intensitas penyiraman,
- atau umur tanaman.

Sering kali hubungan tidak linear:

- pada awalnya, penambahan pupuk meningkatkan hasil,
- tetapi setelah titik tertentu, peningkatannya melambat,
- bahkan bisa menurun jika berlebihan.

Ilustrasi ide

$$\hat{y} = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3$$

dengan:

- x = dosis pupuk
- $\hat{y}$ = prediksi hasil panen

Interpretasi:

- orde rendah: kurva sederhana
- orde lebih tinggi: lebih fleksibel
- terlalu tinggi: risiko overfitting


Mengapa polynomial?

Polynomial cocok ketika pola hubungan berubah **secara halus dan global**, misalnya naik lalu melandai, atau membentuk kurva optimum.


Pesan praktis

Gunakan saat hubungan membentuk **kurva halus** dan ingin tetap mudah dijelaskan.

Contoh Regresi Polynomial



Contoh Regresi Polynomial



1. Regresi Polynomial


Model

$$\hat{y}(x) = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_d x^d$$

- **Filosofi:** satu kurva global menjelaskan seluruh domain input.
- Cocok saat pola cukup halus dan perubahan bentuknya dapat ditangkap oleh kombinasi pangkat rendah sampai menengah.
- Sederhana, mudah dijelaskan, dan mudah dihitung.
- Kelemahan: mudah tidak stabil di tepi domain dan sensitif saat derajat terlalu tinggi.


Intuisi

Setiap pangkat x^m menambah kemampuan kurva untuk membengkok. Derajat menentukan kapasitas model.



Basis polynomial bersifat **global**: satu fungsi mencoba menjelaskan seluruh data

Ilustrasi Python: Regresi Polynomial



```
import numpy as np
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import PolynomialFeatures
from sklearn.linear_model import LinearRegression

x = x.reshape(-1, 1)
model = make_pipeline(
    PolynomialFeatures(degree=5,
                      include_bias=False),
    LinearRegression()
)
model.fit(x, y)
y_pred = model.predict(xx.reshape(-1, 1))
```

- **degree** mengontrol fleksibilitas.
- Degree kecil: bias tinggi.
- Degree besar: varians tinggi dan rawan overfitting.

Transformasi Fitur: Dari x ke Polynomial Basis

Transformasi yang dilakukan

Setiap data x diubah menjadi:

$$x \rightarrow (x, x^2, x^3, x^4, x^5)$$

Dalam bentuk matriks

$$X_{\text{poly}} = \begin{bmatrix} x_1 & x_1^2 & x_1^3 & x_1^4 & x_1^5 \\ x_2 & x_2^2 & x_2^3 & x_2^4 & x_2^5 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ x_n & x_n^2 & x_n^3 & x_n^4 & x_n^5 \end{bmatrix}$$

Makna

Kita menciptakan **ruang fitur baru** yang lebih kaya.

Model Matematis Polynomial Regression

Bentuk model

$$\hat{y}(x) = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 x^4 + \beta_5 x^5$$

Estimasi parameter


$$\min_{\beta} \sum_{i=1}^n (y_i - \hat{y}(x_i))^2$$

- Model tetap linear terhadap parameter β
- Tetapi nonlinear terhadap variabel x

Insight

Nonlinear regression ini sebenarnya adalah **linear regression** di ruang fitur baru.

Ilustrasi Least Squares



- Garis vertikal = error
- Model meminimalkan total error kuadrat

Melihat dari Perspektif Basis Function

Bentuk umum

$$\hat{y}(x) = \beta_0 + \sum_{m=1}^M \beta_m h_m(x)$$

Untuk polynomial

$$h_1(x) = x, \quad h_2(x) = x^2, \quad h_3(x) = x^3, \dots$$

- Setiap $h_m(x)$ adalah **basis function**
- Model adalah kombinasi linear dari basis tersebut

Use Case 2: Medis — Regresi Fungsi Tangga

Contoh kasus

Memprediksi **risiko komplikasi pasien** berdasarkan kadar gula darah, tekanan darah, atau kadar kolesterol.

Dalam praktik klinis, dokter sering memakai **kategori ambang**, misalnya:

- normal,
- borderline,
- tinggi,
- sangat tinggi.

Mengapa step function?

Step function cocok ketika keputusan dibuat berdasarkan **rentang nilai** atau **cut-off klinis**, bukan perubahan yang sepenuhnya halus.

Ilustrasi ide

Misal kadar gula darah dibagi menjadi interval:

$$x < 100, \quad 100 \leq x < 126, \quad x \geq 126$$

Model:

$$\hat{y} = \beta_0 + \beta_1 I(x \in A_1) + \beta_2 I(x \in A_2) + \beta_3 I(x \in A_3)$$

Makna


- Dalam satu interval, prediksi relatif konstan
- Saat melewati ambang, prediksi berubah meloncat
- Sangat mudah dijelaskan ke pengguna non-teknis

2. Regresi Fungsi Tangga (Step Function)

Model

$$\hat{y}(x) = \beta_0 + \sum_{m=1}^M \beta_m \mathbf{1}(c_{m-1} \leq x < c_m)$$

- **Filosofi:** data dibagi menjadi beberapa interval, lalu setiap interval memiliki level rata-rata sendiri.
- Cocok saat kita ingin interpretasi yang sangat sederhana atau ketika perubahan dipandang diskrit per segmen.
- Sangat mudah dibaca: “rentang ini punya respons rata-rata sekian.”
- Kelemahan: batas antar-bin tidak halus dan hasil bergantung pada jumlah serta posisi titik potong.




Basis indikator bersifat **lokal per interval**: perubahan koefisien terutama memengaruhi satu segmen.

Intuisi

Regresi Fungsi Tangga tidak membuat satu kurva halus, tp membangun representasi potongan-potongan konstan.

Ilustrasi Python: Regresi Fungsi Tangga



```
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import KBinsDiscretizer
from sklearn.linear_model import LinearRegression
```

```
x = x.reshape(-1, 1)
model = make_pipeline(
    KBinsDiscretizer(n_bins=8,
                     encode="onehot-dense",
                     strategy="uniform"),
    LinearRegression()
)
model.fit(x, y)
y_pred = model.predict(xx.reshape(-1, 1))
```

- **n_bins** menentukan resolusi model.
- Bin sedikit: terlalu kasar.
- Bin terlalu banyak: sensitif terhadap noise.

Dari Kode ke Ide: Step Function Regression

Potongan kode

```
model = make_pipeline(  
    KBinsDiscretizer(n_bins=8,  
        encode="onehot-dense"),  
    LinearRegression()  
)
```

Pertanyaan penting

Apa yang berubah dari polynomial regression?

- Kita tidak lagi menggunakan x secara langsung
- Kita mengubah x menjadi kategori interval
- Lalu tetap menggunakan regresi linear

Transformasi Fitur: Binning

Pembagian domain

Misalkan $x \in [0, 1]$ dibagi menjadi 8 interval:

$$A_1, A_2, A_3, \dots, A_8$$

Contoh

- $A_1 = [0, 0.125)$
- $A_2 = [0.125, 0.25)$
- ...
- $A_8 = [0.875, 1]$

Makna

Nilai kontinu diubah menjadi **kategori diskrit**.

Representasi One-Hot

Transformasi

$$x \rightarrow (I(x \in A_1), I(x \in A_2), \dots, I(x \in A_8))$$

Contoh

Jika $x \in A_3$:

$$(0, 0, 1, 0, 0, 0, 0, 0)$$

- Setiap interval menjadi satu fitur
- Hanya satu fitur bernilai 1

Insight

Ini adalah **indicator basis function**.

Model Matematis Step Function

Bentuk model

$$\hat{y}(x) = \beta_0 + \sum_{j=1}^8 \beta_j I(x \in A_j)$$

Estimasi parameter

$$\min_{\beta} \sum_{i=1}^n (y_i - \hat{y}(x_i))^2$$

- Model tetap linear terhadap β
- Representasi input berubah drastis

Use Case 3: Industri — Basis Function Regression

Contoh kasus

Memprediksi **kualitas produk** atau **tingkat cacat** berdasarkan: suhu mesin, getaran, tekanan, atau waktu operasi.

Pada sistem industri, pola sering **kompleks dan lokal**:

- pada rentang suhu tertentu kualitas stabil,
- pada area lain terjadi penurunan tajam,
- beberapa efek hanya muncul di wilayah tertentu.

Mengapa basis function?

Basis function cocok ketika hubungan perlu fleksibel, terutama jika pola bersifat **lokal**, **halus**, atau memiliki banyak bentuk kompleks.

Gunakan saat pola data **tidak cukup dijelaskan** oleh satu bentuk kurva global sederhana.

Ilustrasi ide

$$\hat{y}(x) = \beta_0 + \sum_{m=1}^M \beta_m h_m(x)$$

Contoh basis:

- Gaussian RBF
- spline
- Fourier basis

Makna

- tiap basis menangkap pola tertentu
- model akhir adalah kombinasi banyak pola kecil
- lebih fleksibel daripada polynomial global

3. Regresi Basis Function


Model umum

$$\hat{y}(x) = \beta_0 + \sum_{m=1}^M \beta_m h_m(x)$$

- **Filosofi:** kita merancang basis sesuai geometri masalah.
- Polynomial dan step function sebenarnya hanyalah kasus khusus dari pendekatan basis function.
- Kita dapat memilih basis yang **global** atau **lokal**, **halus** atau **periodik**.


Contoh basis

- **Spline:** halus dan lokal
- **Gaussian RBF:** lokal di sekitar pusat tertentu
- **Fourier:** cocok untuk pola periodik



Basis lokal memberi fleksibilitas tinggi tanpa harus menggoyang seluruh kurva.

Ilustrasi Python: Basis Function dengan Gaussian RBF



```
import numpy as np
from sklearn.pipeline import make_pipeline
from sklearn.linear_model import LinearRegression
```

```
class RBFFeatures:
    def __init__(self, centers, gamma=90):
        self.centers = np.asarray(centers)
        self.gamma = gamma
    def fit(self, X, y=None):
        return self
    def transform(self, X):
        X = np.asarray(X).reshape(-1, 1)
        return np.exp(-self.gamma *
                        (X - self.centers)**2)

centers = np.linspace(0, 1, 12).reshape(1, -1)
model = make_pipeline(RBFFeatures(centers),
                      LinearRegression())
```

- Banyaknya pusat dan nilai **gamma** mengontrol kelokalan basis.

Dari Kode ke Ide: RBF Regression

Potongan kode

```
class RBFFeatures:  
    def transform(self, X):  
        return exp(-gamma * (X - centers)^2)  
  
model = make_pipeline(RBFFeatures(centers),  
                      LinearRegression())
```

Pertanyaan penting

Apa yang berubah dibanding polynomial dan step function?

- Kita tidak menggunakan x langsung
- Kita membentuk fitur berbasis jarak terhadap titik tertentu
- Lalu tetap menggunakan regresi linear

Transformasi Fitur: Gaussian Basis

Fungsi basis

$$h_j(x) = \exp(-\gamma(x - c_j)^2)$$

Transformasi


$$x \rightarrow (h_1(x), h_2(x), \dots, h_M(x))$$

- c_j = center (titik referensi)
- setiap basis aktif di sekitar center

Makna

Kita merepresentasikan x berdasarkan **kedekatannya terhadap beberapa titik**.

Ilustrasi Gaussian RBF



Setiap kurva adalah satu basis $h_j(x)$ dengan center berbeda

Matriks fitur

$$\Phi = \begin{bmatrix} h_1(x_1) & h_2(x_1) & \dots & h_M(x_1) \\ h_1(x_2) & h_2(x_2) & \dots & h_M(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ h_1(x_n) & h_2(x_n) & \dots & h_M(x_n) \end{bmatrix}$$

- Setiap kolom = satu Gaussian basis
- Setiap baris = representasi satu data

Model Matematis RBF Regression

Bentuk model

$$\hat{y}(x) = \beta_0 + \sum_{j=1}^M \beta_j \exp(-\gamma(x - c_j)^2)$$

Estimasi parameter

$$\min_{\beta} \sum_{i=1}^n (y_i - \hat{y}(x_i))^2$$

- Linear terhadap parameter β
- Nonlinear terhadap x

Intuisi: Fungsi Lokal

Karakteristik

- Setiap basis berbentuk lonceng (Gaussian)
- Nilai tinggi dekat center
- Nilai kecil jauh dari center

Makna

- Model belajar secara lokal
- Setiap bagian domain punya pengaruh sendiri

Insight

RBF adalah **kombinasi banyak fungsi lokal kecil**.

Intuisi Gaussian RBF: Basis Lokal

Fungsi basis

$$h_j(x) = \exp(-\gamma(x - c_j)^2)$$

- Setiap kurva berpusat di c_j
- Nilai maksimum terjadi di center
- Semakin jauh dari center $\rightarrow$ nilai mengecil


Peran γ

- γ besar $\rightarrow$ kurva sempit (sangat lokal)
- γ kecil $\rightarrow$ kurva lebar (lebih global)

Makna

- Setiap basis = **fungsi lokal**
- Hanya aktif di sekitar center

Ilustrasi Gaussian RBF



Garis berwarna = basis individu
Garis putus-putus = kombinasi semua basis

- Lebar kurva pada gambar dikontrol oleh γ
- Model akhir adalah kombinasi banyak fungsi lokal kecil yang saling overlap.

Filosofi Intuisi: Model Nonlinear

Polynomial Regression

“Satu cerita besar untuk semua data”

- Mencari satu fungsi global
- Semua titik dipengaruhi secara bersama
- Cocok untuk pola halus dan kontinu

Step Function Regression

“Memecah dunia menjadi kategori”

- Domain dibagi menjadi segmen
- Setiap segmen punya aturan sendiri
- Cocok untuk sistem berbasis ambang

Basis Function (RBF)

“Banyak sudut pandang lokal”

- Setiap basis melihat area kecil
- Model adalah kombinasi perspektif lokal
- Cocok untuk pola kompleks dan tidak seragam

Intuisi besar

- Polynomial → berpikir **global**
- Step function → berpikir **diskrit**
- RBF → berpikir **lokal**

Pesan penting

Bukan modelnya yang berbeda, tetapi
cara kita merepresentasikan dan memahami data.

Kapan memakai metode yang mana?

Polynomial	Step Function	Basis Function
• Pola halus global • Domain sempit • Ingin model sederhana	• Ingin segmentasi kasar • Perlu interpretasi interval • Hubungan tidak perlu halus	• Pola kompleks dan lokal • Ingin fleksibilitas terkontrol • Siap melakukan tuning basis

Penutup filosofis

Nonlinear regression bukan sekadar menggambar kurva bengkok. Intinya adalah **mewakili realitas dengan basis yang sesuai**, lalu mengestimasi bobotnya secara sistematis.