

Kuliah 10-Pengenalan Machine Learning

Konsep Dasar, Tahapan, Evaluasi, dan Use Case

Yeni Herdiyeni
Prodi Kecerdasan Buatan
SSMI-IPB University

22 April 2026

- Menjelaskan konsep *learning* dalam machine learning.
- Memahami tahapan utama dalam workflow machine learning.
- Menjelaskan mengapa model perlu dievaluasi.
- Membedakan underfitting, overfitting, dan model yang seimbang.
- Memahami use case regresi sebagai contoh penerapan machine learning.

- **Artificial Intelligence (AI)**

- Bidang luas untuk membangun sistem yang mampu meniru kecerdasan manusia
- Contoh: reasoning, planning, problem solving, perception

- **Machine Learning (ML)**

- Subset dari AI yang berfokus pada sistem yang *belajar dari data*
- Tidak diprogram secara eksplisit, tetapi belajar pola dari data
- Contoh: klasifikasi, prediksi, clustering

- **Data Science**

- Bidang yang berfokus pada pengolahan data untuk menghasilkan insight
- Mencakup: data collection, cleaning, analysis, visualization
- Machine learning adalah salah satu tools dalam data science

Tingkatan Data Analytics

Diagnostic Analytics

- Mengapa ini terjadi?
- Analisis penyebab
- Contoh: Mengapa hasil panen menurun?

Predictive Analytics

- Apa yang akan terjadi?
- Menggunakan machine learning
- Contoh: Prediksi hasil panen

Prescriptive Analytics

- Apa yang sebaiknya dilakukan?
- Memberikan rekomendasi
- Contoh: Waktu tanam optimal



Mengapa Kita Perlu Machine Learning?

Use Case: Prediksi Produksi Tanaman

Input:

- Curah hujan
- Suhu
- Kelembaban tanah
- Jenis tanah
- Pupuk

Output:

- Hasil panen (ton/ha)

Pendekatan Tradisional

- Sulit membuat aturan pasti
- Banyak faktor saling berinteraksi
- Bersifat subjektif

Pendekatan Machine Learning

- Belajar dari data historis
- Menangkap pola kompleks
- Prediksi lebih akurat


Apa Itu Machine Learning?

Machine learning adalah pendekatan dalam kecerdasan buatan yang memungkinkan sistem **belajar dari data** untuk menemukan pola dan menghasilkan prediksi atau keputusan.

Ide utama:

- Kita tidak menulis semua aturan secara eksplisit.
- Sistem belajar hubungan antara input dan output dari contoh data.
- Hasil belajar direpresentasikan dalam bentuk **model**.

Machine Learning Pipeline: From Data to Deployment



Made with Napkin

Use Case: Prediksi Hasil Panen

Data (Pengalaman)

- Curah hujan
- Suhu
- Kelembaban tanah
- Jenis pupuk

Target (Label)

- Hasil panen (ton/ha)

Proses Learning

- Model belajar dari data historis
- Menemukan pola hubungan input-output
- Menyesuaikan parameter model

Output

- Prediksi hasil panen baru

Learning = Data + Model + Penyesuaian → Prediksi

Use Case: Data Understanding (Exploratory Data Analysis)

Use Case

- Prediksi hasil panen padi
- Sebelum modeling, kita perlu memahami data

Pertanyaan EDA

- Bagaimana distribusi curah hujan?
- Apakah suhu berkorelasi dengan hasil panen?
- Apakah terdapat outlier pada data?
- Fitur mana yang paling berpengaruh?

Tujuan


- Memahami karakteristik data
- Mengidentifikasi masalah (noise, missing values, outlier)
- Menentukan strategi modeling yang tepat

Insight

- Model yang baik selalu diawali dengan pemahaman data yang baik

Contoh EDA plot

EDA 4-plots




Learning pada machine learning adalah proses menyesuaikan model agar kesalahan prediksi semakin kecil.

Komponen utama:

- **Input X :** fitur yang diamati
- **Target y :** nilai sebenarnya
- **Model f :** pemetaan $X \rightarrow y$
- **Loss/Error:** ukuran kesalahan

$$\hat{y} = f(X)$$



Ilustrasi proses learning: input $\rightarrow$ model $\rightarrow$ prediksi
 $\rightarrow$ error

Pemrograman Tradisional vs Machine Learning

Pemrograman Tradisional

- Data + aturan diberikan programmer
- Sistem menghasilkan output
- Cocok jika aturan jelas

Machine Learning

- Data + contoh output diberikan ke model
- Sistem belajar pola sendiri
- Cocok jika aturan sulit ditulis manual

Contoh: memprediksi harga rumah, deteksi penyakit, prediksi hasil panen, prediksi curah hujan.

- **Supervised Learning:** belajar dari data yang memiliki target/label.
 - Contoh: prediksi harga rumah, klasifikasi email spam.
- **Unsupervised Learning:** belajar dari data tanpa label untuk menemukan pola tersembunyi.
 - Contoh: segmentasi pelanggan, pengelompokan wilayah pertanian.
- **Reinforcement Learning:** belajar melalui interaksi, aksi, dan reward.

Supervised Learning

Konsep


- Belajar dari data yang memiliki **label/target**
- Model mempelajari hubungan antara input dan output

Tujuan

- Melakukan prediksi terhadap data baru

Contoh

- Prediksi harga rumah
- Klasifikasi email spam



Input $X \rightarrow$ Model $\rightarrow$ Output y

Unsupervised Learning

Konsep


- Belajar dari data **tanpa label**
- Model mencari pola tersembunyi dalam data

Tujuan

- Mengelompokkan atau menyederhanakan data

Contoh

- Segmentasi pelanggan
- Pengelompokan wilayah pertanian



Data → Pola / Cluster

Reinforcement Learning

Konsep


- Belajar melalui **interaksi**
- Menggunakan aksi dan feedback (reward)

Komponen

- Agent
- Environment
- Reward

Contoh

- Robot navigasi
- Sistem rekomendasi adaptif



Agent $\leftrightarrow$ Environment $\rightarrow$ Reward

Use Case Machine Learning dalam Kehidupan Nyata

- **Pendidikan:** prediksi mahasiswa berisiko terlambat lulus.
- **Kesehatan:** prediksi kemungkinan penyakit dari hasil pemeriksaan.
- **Pertanian:** prediksi hasil panen berdasarkan curah hujan, suhu, dan kelembapan.
- **Kelautan:** prediksi wilayah potensi penangkapan ikan dari data oseanografi.
- **Bisnis:** rekomendasi produk dan prediksi churn pelanggan.

Tahapan Machine Learning

- 1 Menentukan masalah dan tujuan
- 2 Mengumpulkan data
- 3 Pra-pemrosesan data
- 4 Membagi data: training, validation, testing
- 5 Melatih model
- 6 Mengevaluasi model
- 7 Memilih model terbaik
- 8 Deployment dan monitoring

1. Problem Formulation dan Data Preparation

Problem formulation

- Apa yang ingin diprediksi?
- Apakah masalahnya regresi atau klasifikasi?
- Apa metrik keberhasilannya?

Data preparation

- Membersihkan missing values dan noise
- Memilih fitur yang relevan
- Melakukan encoding/normalisasi jika diperlukan

2. Training, Validation, dan Testing

Training Set

Digunakan untuk **melatih** model dan menyesuaikan parameter.

Validation Set

Digunakan untuk **memilih model** atau *hyperparameter* yang paling baik.

Test Set

Digunakan untuk **menilai performa akhir** model pada data yang benar-benar belum pernah dilihat.

Intuisi: training untuk belajar, validation untuk memilih, testing untuk menguji secara final.

Data Mentah → Pra-pemrosesan → Training



Validation →



Testing → Deployment

3. Deployment dan Monitoring

Deployment berarti model digunakan pada lingkungan nyata.

Contoh deployment:

- Sistem prediksi harga komoditas di dashboard.
- Model prediksi risiko pasien di rumah sakit.
- Sistem rekomendasi lokasi tanam untuk petani.

Monitoring diperlukan karena:

- data baru bisa berubah pola
- performa model bisa menurun
- model perlu diperbarui secara berkala

Mengapa Model Harus Dievaluasi?

Model yang terlihat bagus pada data training belum tentu bagus pada data baru.

Evaluasi model bertujuan untuk:

- mengukur kualitas prediksi
- membandingkan beberapa model
- mendeteksi underfitting atau overfitting
- memastikan model layak digunakan

Untuk masalah regresi, beberapa metrik umum adalah:

- **MAE** (Mean Absolute Error)
- **MSE** (Mean Squared Error)
- **RMSE** (Root Mean Squared Error)
- R^2 (Koefisien determinasi)

Intuisi umum:

- Error kecil $\rightarrow$ prediksi lebih baik
- R^2 besar $\rightarrow$ model menjelaskan variasi data lebih baik

Untuk masalah klasifikasi, metrik yang umum digunakan:

- Akurasi
- Precision
- Recall
- F1-score
- Confusion matrix

Contoh: pada deteksi penyakit, recall sering penting agar kasus positif tidak banyak terlewat.

Use Case: Evaluasi Model di Dunia Nyata

Kasus 1: Prediksi hasil panen

Metrik yang cocok: MAE, RMSE

Kasus 2: Deteksi tanaman sakit vs sehat


Metrik yang cocok: precision, recall, F1-score

Kasus 3: Prediksi wilayah penangkapan ikan

Metrik dapat dipilih sesuai target: error prediksi, akurasi klasifikasi, atau metrik spasial tertentu

Pemilihan Model Terbaik

Dalam praktiknya, kita tidak hanya mencari model yang akurat pada training set, tetapi model yang **mampu melakukan generalisasi**.



Ciri-ciri:

- Model terlalu sederhana
- Tidak mampu menangkap pola penting
- Error training dan testing sama-sama tinggi

Contoh: menggunakan model linear sederhana untuk data yang pola hubungan sebenarnya sangat non-linear.

Ciri-ciri:

- Model terlalu kompleks
- Sangat baik pada training set
- Buruk pada validation atau test set

Penyebab umum:

- terlalu banyak parameter
- data training terlalu sedikit
- model menangkap noise

Ciri-ciri:

- Cukup kompleks untuk menangkap pola utama
- Tidak terlalu sensitif terhadap noise
- Performa training dan testing sama-sama baik

Tujuan utama machine learning: menemukan model yang seimbang antara akurasi dan generalisasi.

Ilustrasi Konseptual Pemilihan Model

Kondisi	Kompleksitas	Train Error	Test Error
Underfitting	Rendah	Tinggi	Tinggi
Balanced	Sedang	Rendah	Rendah
Overfitting	Tinggi	Sangat rendah	Tinggi

Bagaimana Memilih Model?

- Mulai dari model sederhana
- Evaluasi dengan validation set
- Bandingkan beberapa model dan parameter
- Pilih model yang paling baik pada data validasi, bukan hanya training
- Gunakan test set hanya untuk evaluasi akhir

Tujuan regresi: memprediksi nilai numerik atau kontinu.

Contoh target regresi:

- harga rumah
- suhu udara
- hasil panen
- jumlah produksi ikan

Use Case Regresi: Prediksi Hasil Panen Padi

Misalkan kita ingin memprediksi **hasil panen padi (ton/ha)** berdasarkan beberapa fitur:

- curah hujan
- suhu rata-rata
- kelembapan tanah
- penggunaan pupuk

Masalah ini adalah supervised learning jenis regresi, karena target yang diprediksi berupa nilai kontinu.

Dataset

- Data historis budidaya padi
- Setiap baris data memiliki:
 - fitur (X)
 - hasil panen (y)

Contoh fitur

- Curah hujan (mm)
- Suhu ($^{\circ}\text{C}$)
- Kelembaban tanah (%)
- Pupuk (kg/ha)

Contoh data:

	rainfall	temperature	soil_moisture	fertilizer	yield_ton
0	174.908024	32.074402	77.618343	227.633985	4.939113
1	290.142861	32.960913	78.157143	278.657644	6.372760
2	246.398788	27.180035	76.594576	241.650578	6.953359
3	219.731697	25.100519	54.806348	259.123358	4.753269
4	131.203728	26.279352	40.618265	338.292962	4.399777
5	131.198904	28.271078	77.132743	227.220528	4.328470
6	111.616722	32.180148	57.127366	342.238113	4.630280
7	273.235229	32.607306	78.666193	331.070128	5.778786
8	220.223002	24.069521	78.544799	189.158227	5.267445
9	241.614516	29.107473	74.120378	163.872260	4.509350

Representasi data input-output


Pipeline: Pembagian Data

Mengapa data dibagi?

- **Training set:** melatih model
- **Validation set:** memilih model/menyetel parameter
- **Testing set:** menguji performa akhir

Contoh proporsi

- Training: 60%
- Validation: 20%
- Testing: 20%



Ilustrasi pembagian data training, validation, dan testing

Model mencoba memetakan fitur ke hasil panen

$$\hat{y} = f(X)$$

Contoh

$$\hat{y} = w_1 \cdot \text{curah hujan} + w_2 \cdot \text{suhu} + w_3 \cdot \text{kelembaban tanah} + w_4 \cdot \text{pupuk}$$

- Model memiliki parameter w
- Parameter dipelajari dari data training

Proses Learning

- Model menerima data training
- Menghasilkan prediksi $\hat{y}$
- Membandingkan prediksi dengan nilai sebenarnya y
- Menghitung error
- Menyesuaikan parameter model

$$\text{Error} = y - \hat{y}$$

Tujuan

- Meminimalkan error agar prediksi semakin akurat

Pipeline: Evaluasi Model


Evaluasi dilakukan pada validation dan testing set

Metric regresi

- Mean Absolute Error (MAE)
- Mean Squared Error (MSE)
- R^2

Tujuan evaluasi

- Mengukur performa model
- Mendeteksi overfitting
- Memilih model terbaik



Perbandingan hasil prediksi dan nilai aktual untuk mengevaluasi performa model

Perbandingan Metrik (Perhitungan) — Prediksi Hasil Panen

Use Case

- Aktual: [6.0, 5.0] ton/ha
- Prediksi: [5.5, 3.0]

Error

- $e_1 = 0.5$
- $e_2 = 2.0$

MAE

$$\text{MAE} = \frac{|0.5| + |2.0|}{2} = 1.25$$

MSE

$$\text{MSE} = \frac{0.5^2 + 2.0^2}{2} = \frac{0.25 + 4}{2} = 2.125$$

RMSE

$$\text{RMSE} = \sqrt{2.125} \approx 1.46$$

MAPE

$$\text{MAPE} = \frac{1}{2} \left(\frac{0.5}{6.0} + \frac{2.0}{5.0} \right) \times 100\% \approx 24.2\%$$

Interpretasi awal

- Error kecil: 0.5
- Error besar: 2.0
- MSE/RMSE memberi penalti lebih besar pada error 2.0

R^2 (Koefisien Determinasi)

- Mengukur seberapa baik model mengikuti pola data
- Tidak menunjukkan besar error secara langsung

Makna tiap metrik

• MAE

- Rata-rata kesalahan = 1.25 ton/ha

• MSE

- Error besar sangat berpengaruh

• RMSE

- Error dalam satuan asli = 1.46 ton/ha
- Lebih mudah dipahami daripada MSE

• MAPE

- Error $\approx 24\%$
- Mudah dikomunikasikan ke petani/stakeholder

Pipeline: Prediksi Hasil Panen

Setelah model dilatih dan dievaluasi


- Masukkan data lahan baru
- Model memprediksi hasil panen

Contoh input baru

- Curah hujan = 220 mm
- Suhu = 28°C
- Kelembaban tanah = 68%
- Pupuk = 260 kg/ha

Manfaat

- Perencanaan budidaya
- Estimasi produktivitas lahan



Prediksi vs nilai aktual (model regresi)

$$\hat{y} = f(X_{\text{baru}})$$

Alur Berpikir pada Use Case Regresi

- ➊ Tentukan target: hasil panen
- ➋ Kumpulkan data historis
- ➌ Bagi data menjadi training, validation, testing
- ➍ Latih model regresi
- ➎ Evaluasi error prediksi
- ➏ Pilih model terbaik
- ➐ Gunakan model untuk prediksi musim berikutnya

- Machine learning adalah proses belajar dari data untuk membangun model.
- Workflow ML mencakup training, validation, testing, dan deployment.
- Evaluasi model penting untuk memastikan generalisasi.
- Pemilihan model harus mempertimbangkan underfitting, overfitting, dan keseimbangan.
- Regresi adalah contoh supervised learning untuk memprediksi nilai kontinu.