

Supervised dan Unsupervised Learning

Studi Kasus: Analisis dan Prediksi Produktivitas Padi

Yeni Herdiyeni
Program Studi Kecerdasan Buatan
Sekolah Sains Data, Matematika dan Informatika
IPB University

April 29, 2026

Tujuan Pembelajaran

Setelah mengikuti materi ini, mahasiswa diharapkan mampu:

- 1 Menjelaskan motivasi penggunaan machine learning.
- 2 Membedakan supervised, unsupervised, dan reinforcement learning.
- 3 Menjelaskan peran EDA dalam pipeline machine learning.
- 4 Melakukan feature engineering berdasarkan temuan EDA.
- 5 Memahami konsep evaluasi model supervised dan unsupervised.
- 6 Menginterpretasikan hasil model dalam konteks kasus pertanian.

Use Case: Produktivitas Padi

Masalah utama:

Petani dan pengambil kebijakan ingin memahami faktor yang memengaruhi hasil panen padi.

Data yang tersedia:

- Curah hujan
- Suhu
- Kelembaban
- Jumlah pupuk
- Luas lahan
- Hasil panen

Pertanyaan Data Science

Bagaimana data ini dapat digunakan untuk memprediksi hasil panen dan memahami pola lahan?

Motivasi Machine Learning

Pada pendekatan tradisional, kita membuat aturan secara manual.

Contoh aturan manual

Jika curah hujan tinggi dan pupuk cukup, maka hasil panen tinggi.

Namun dalam dunia nyata:

- Hubungan antar variabel tidak selalu sederhana.
- Curah hujan terlalu tinggi justru dapat menurunkan hasil panen.
- Kombinasi suhu, pupuk, dan kelembaban dapat membentuk pola kompleks.

Motivasi ML

Machine learning digunakan ketika pola dalam data sulit dirumuskan secara eksplisit dengan aturan manual.

Tiga Paradigma Machine Learning

Paradigma	Data	Contoh dalam Use Case
Supervised Learning	Ada input dan target	Prediksi hasil panen berdasarkan cuaca dan pupuk
Unsupervised Learning	Hanya input, tanpa target	Segmentasi lahan berdasarkan karakteristiknya
Reinforcement Learning	Belajar dari aksi dan reward	Sistem irigasi otomatis belajar kapan memberi air

Mengapa Tidak Langsung Modeling?

Kesalahan umum dalam machine learning adalah langsung membuat model tanpa memahami data.

Risiko:

- Model belajar dari data yang salah.
- Outlier dapat merusak hasil prediksi.
- Relasi non-linear tidak tertangkap oleh model sederhana.
- Fitur penting dan tidak penting tidak dibedakan.

Pertanyaan Kritis

Sebelum membuat model, apakah kita sudah memahami karakteristik datanya?

Peran EDA dalam Machine Learning

Exploratory Data Analysis (EDA) adalah tahap untuk memahami data sebelum modeling.

EDA membantu menjawab:

- Bagaimana distribusi setiap variabel?
- Apakah ada data ekstrem atau outlier?
- Apakah hubungan antar variabel linear atau non-linear?
- Fitur mana yang tampak relevan terhadap target?

Ide Utama

EDA bukan sekadar membuat grafik, tetapi proses berpikir untuk menentukan strategi modeling.

EDA 1: Distribusi Curah Hujan

Pertanyaan:


- Apakah curah hujan tersebar merata?
- Apakah ada nilai ekstrem?

Insight:

- Data dapat bersifat skewed.
- Nilai ekstrem perlu diperiksa.

Keputusan:

- Lakukan scaling.
- Pertimbangkan transformasi fitur.



EDA 2: Relasi Curah Hujan dan Hasil Panen

Pertanyaan:


- Apakah semakin tinggi hujan selalu meningkatkan panen?

Insight:

- Relasi dapat berbentuk non-linear.
- Ada titik optimal curah hujan.

Keputusan:

- Tambahkan fitur kuadrat.
- Gunakan model yang mampu menangkap pola non-linear.



EDA 3: Outlier pada Hasil Panen

Pertanyaan:


- Apakah hasil panen sangat rendah merupakan error?

Insight:

- Hasil panen mendekati nol bisa menjadi kasus gagal panen.
- Outlier tidak selalu salah.

Keputusan:

- Jangan langsung menghapus outlier.
- Periksa makna domainnya.



EDA 4: Korelasi Antar Variabel

Pertanyaan:


- Fitur mana yang berkaitan dengan hasil panen?

Insight:

- Beberapa fitur lebih berhubungan dengan target.
- Korelasi membantu indikasi awal, bukan bukti kausal.

Keputusan:

- Lakukan feature selection.
- Hindari memakai fitur yang tidak relevan secara berlebihan.



Dari EDA ke Keputusan Modeling

Temuan EDA	Keputusan	Dampak ke Model
Data skewed	Scaling / transformasi	Model lebih stabil
Relasi non-linear	Tambah fitur kuadrat	Pola lebih tertangkap
Outlier bermakna	Tidak langsung dihapus	Model tetap merekam kasus ekstrem
Fitur lemah	Feature selection	Model lebih sederhana

Feature Engineering

Feature engineering adalah proses membentuk fitur agar lebih representatif bagi model.

Contoh pada use case:

- **Fitur kuadrat:**

$$rainfall^2$$

untuk menangkap relasi non-linear.

- **Fitur rasio:**

$$fertilizer_per_area = \frac{fertilizer}{land_area}$$

- **Kategori curah hujan:** rendah, sedang, tinggi.

Intuisi

Feature engineering adalah cara memasukkan pemahaman domain ke dalam data.

Supervised Learning: Prediksi Hasil Panen

Dalam supervised learning, data memiliki pasangan input dan target.

$$(X, y)$$

Pada use case ini:

$$X = \{\text{curah hujan, suhu, kelembaban, pupuk, luas lahan}\}$$

$$y = \text{hasil panen}$$

Tujuan

Model belajar fungsi:

$$f(X) \rightarrow y$$

untuk memprediksi hasil panen dari data baru.

Model sederhana: Linear Regression

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

Namun karena EDA menunjukkan relasi non-linear, kita tambahkan:

$$\hat{y} = \beta_0 + \beta_1 \text{rainfall} + \beta_2 \text{rainfall}^2 + \dots$$

Makna Penting

Model tetap linear terhadap parameter, tetapi mampu menangkap pola non-linear melalui transformasi fitur.


Visualisasi Model Supervised

Interpretasi:

- Titik menunjukkan data aktual.
- Garis menunjukkan prediksi model.
- Pola melengkung muncul karena fitur kuadrat.

Pesan

EDA membantu kita memilih representasi fitur yang lebih tepat.



Evaluasi Supervised Learning

Untuk kasus prediksi hasil panen, evaluasi dapat menggunakan:

- **MAE**

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- **RMSE**

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- R^2

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$


Interpretasi

Semakin kecil MAE/RMSE dan semakin besar R^2 , semakin baik model menjelaskan data.

Actual vs Predicted

Cara membaca grafik:

- Jika titik dekat garis diagonal, prediksi baik.
- Jika titik jauh dari garis, error besar.
- Titik ekstrem dapat menunjukkan kasus gagal panen.



Unsupervised Learning: Segmentasi Lahan

Dalam unsupervised learning, data tidak memiliki target.

$$X = \{\text{curah hujan, pupuk, suhu, hasil panen}\}$$

Tujuan:

- Menemukan kelompok lahan/petani yang mirip.
- Memahami pola tersembunyi dalam data.

Contoh Pertanyaan

Apakah terdapat kelompok lahan dengan kondisi input dan hasil panen yang berbeda?

Contoh Model Unsupervised: K-Means

K-Means membagi data ke dalam K cluster.

$$\min \sum_{k=1}^K \sum_{x_i \in C_k} ||x_i - \mu_k||^2$$

Intuisi:

- Data yang mirip ditempatkan dalam cluster yang sama.
- Setiap cluster memiliki pusat yang disebut centroid.


Catatan

Hasil clustering harus diinterpretasikan dengan domain knowledge.

Visualisasi Clustering

Interpretasi:

- Setiap warna menunjukkan cluster.
- Cluster dapat menggambarkan pola lahan berbeda.
- Misalnya: lahan input tinggi, sedang, atau rendah.



Evaluasi Unsupervised Learning

Evaluasi clustering tidak sesederhana supervised learning karena tidak ada label benar.

Salah satu metrik yang digunakan adalah **Silhouette Score**.

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

- $a(i)$: rata-rata jarak ke titik dalam cluster yang sama.
- $b(i)$: rata-rata jarak ke cluster terdekat.

Interpretasi

Nilai mendekati 1 menunjukkan cluster lebih terpisah dengan baik.

Evaluasi Clustering: Elbow Method


Ide Dasar

Elbow method digunakan untuk menentukan jumlah cluster optimal (K).

Langkah:

- Hitung WCSS (Within Cluster Sum of Squares)
- Ulangi untuk berbagai nilai K
- Plot K vs WCSS

$$WCSS = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$



Contoh Elbow Method untuk menentukan jumlah cluster


- Penurunan tajam $\rightarrow$ cluster membaik
- Titik "siku" (elbow) $\rightarrow K$ optimal

Pertanyaan interpretatif:

- Cluster mana yang rata-rata hasil panennya tinggi?
- Apakah cluster tertentu memiliki pupuk lebih tinggi?
- Apakah cluster tertentu rentan hasil rendah?

Insight

Clustering bukan akhir analisis, tetapi awal untuk memahami segmentasi data.



Reinforcement Learning dalam Use Case

Walaupun fokus praktikum adalah supervised dan unsupervised, reinforcement learning juga dapat muncul dalam pertanian.

Contoh: sistem irigasi otomatis

- Agent: sistem irigasi.
- Environment: lahan pertanian.
- Action: memberi air atau tidak.
- Reward: peningkatan hasil panen atau efisiensi air.

Intuisi

Reinforcement learning cocok ketika sistem harus belajar mengambil keputusan secara bertahap melalui feedback.

Pipeline Machine Learning End-to-End

1 Problem Definition

Menentukan masalah dan tujuan analisis.

2 Data Collection

Mengumpulkan data cuaca, lahan, pupuk, dan hasil panen.

3 EDA

Memahami pola, outlier, dan relasi.

4 Feature Engineering

Membentuk fitur baru berdasarkan insight EDA.

5 Modeling

Supervised atau unsupervised learning.

6 Evaluation

Mengukur kinerja model.

7 Deployment

Menggunakan model untuk membantu keputusan.

Deployment: Dari Model ke Keputusan

Model machine learning tidak berhenti pada akurasi.

Contoh deployment:

- Dashboard prediksi hasil panen.
- Sistem rekomendasi kebutuhan pupuk.
- Peta segmentasi lahan berdasarkan cluster.
- Peringatan dini risiko gagal panen.

Pesan Utama

Nilai utama model adalah ketika hasilnya dapat digunakan untuk mendukung keputusan nyata.

Kode Program: Generate Data

```
import numpy as np
import pandas as pd

np.random.seed(42)
n = 180

rainfall = np.random.normal(180, 45, n)
temperature = np.random.normal(27, 2.2, n)
humidity = np.random.normal(75, 8, n)
fertilizer = np.random.normal(110, 25, n)
land_area = np.random.uniform(0.5, 3.0, n)

rain_effect = -0.0009 * (rainfall - 180)**2 + 5.5
fert_effect = 0.025 * fertilizer
temp_effect = -0.08 * (temperature - 27)**2 + 1.2

yield_ton_ha = rain_effect + fert_effect + temp_effect
```

Kode Program: Feature Engineering

```
df["rainfall_squared"] = df["rainfall"] ** 2

df["fertilizer_per_area"] = (
df["fertilizer"] / df["land_area"]
)

df["rainfall_category"] = pd.cut(
df["rainfall"],
bins=[-np.inf, 140, 220, np.inf],
labels=["rendah", "sedang", "tinggi"]
)
```

Makna

Fitur baru dibentuk berdasarkan insight EDA, bukan sekadar coba-coba.

Kode Program: Supervised Learning

```
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error,
    mean_squared_error

features = [
    "rainfall",
    "rainfall_squared",
    "temperature",
    "humidity",
    "fertilizer",
    "land_area"
]

X = df[features]
y = df["yield_ton_ha"]

model = LinearRegression()
model.fit(X, y)

y_pred = model.predict(X)
```

Kode Program: Unsupervised Learning

```
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import silhouette_score

X_cluster = df[
    ["rainfall", "fertilizer", "temperature", "yield_ton_ha"]
]

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X_cluster)

kmeans = KMeans(n_clusters=3, random_state=42)
labels = kmeans.fit_predict(X_scaled)

score = silhouette_score(X_scaled, labels)
```

Ringkasan: Satu Use Case, Banyak Pendekatan

Tujuan	Pendekatan	Output
Prediksi hasil panen	Supervised Learning	Nilai hasil panen
Segmentasi lahan	Unsupervised Learning	Kelompok lahan
Optimasi irigasi	Reinforcement Learning	Kebijakan aksi

Kesimpulan

Jenis machine learning dipilih berdasarkan bentuk masalah dan ketersediaan label.

Kesimpulan Utama

- 1 Machine learning digunakan ketika pola data sulit dibuat dengan aturan manual.
- 2 EDA adalah fondasi penting sebelum modeling.
- 3 Feature engineering harus didasarkan pada insight dari data.
- 4 Supervised learning digunakan untuk prediksi dengan label.
- 5 Unsupervised learning digunakan untuk menemukan struktur tersembunyi.
- 6 Evaluasi model harus disesuaikan dengan jenis masalah.

Pesan Akhir

Model yang baik bukan hanya akurat, tetapi juga dapat dijelaskan dan berguna untuk pengambilan keputusan.