

Kuliah 11-Shrinkage Methods dalam Sains Data

Ridge dan Lasso Regression

Pengantar Sains Data
Yeni Herdiyeni
Prodi Sarjana Kecerdasan Buatan

Materi ini akan dibahas secara bertahap melalui lima langkah utama:

- ➊ memahami **use case** prediksi hasil panen padi;
- ➋ mengenal **OLS** sebagai model dasar regresi linear;
- ➌ melihat **permasalahan OLS** pada data dengan fitur yang saling berkorelasi;
- ➍ memahami bagaimana **Ridge** mengatasi masalah tersebut dengan menyusutkan semua koefisien;
- ➎ memahami bagaimana **Lasso** menyusutkan koefisien sekaligus melakukan seleksi fitur.

1. Use Case: Prediksi Hasil Panen Padi


Kasus

Kita ingin memprediksi **hasil panen padi** berdasarkan sejumlah variabel lingkungan dan budidaya.

Contoh fitur yang digunakan

- curah hujan (*rainfall*)
- kelembapan udara (*humidity*)
- temperatur
- kelembapan tanah
- irigasi
- pupuk A dan pupuk B
- cahaya matahari
- pH tanah
- indeks hama

Tujuan Membangun model yang dapat memperkirakan hasil panen berdasarkan kombinasi seluruh variabel tersebut.



Contoh hubungan satu fitur (*rainfall*) dengan target *yield*.

Mengapa Kasus Ini Menarik untuk Dipelajari?

Kenyataan pada data nyata

Faktor-faktor yang memengaruhi hasil panen biasanya **tidak berdiri sendiri**. Banyak variabel bergerak bersama dan saling berhubungan.

- Saat curah hujan meningkat, kelembapan tanah sering ikut meningkat.
- Temperatur dapat berhubungan dengan kelembapan udara.
- Pupuk A dan pupuk B dapat memiliki pola penggunaan yang mirip.

Akibatnya

Model menjadi lebih sulit membedakan **mana pengaruh murni dari tiap variabel**. Di sinilah persoalan regresi mulai muncul.

2. Apa Itu OLS?

Ordinary Least Squares (OLS)

OLS adalah metode regresi linear yang mencari model terbaik dengan cara **meminimalkan jumlah kuadrat error** antara nilai aktual dan nilai prediksi.

$$\min \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- y_i : hasil panen aktual
- $\hat{y}_i$: hasil panen yang diprediksi model

Dalam use case ini

$$\text{yield} = \beta_0 + \beta_1(\text{rainfall}) + \beta_2(\text{temperature}) + \dots + \beta_p(\text{pest index})$$

Koefisien β menunjukkan seberapa besar kontribusi masing-masing fitur terhadap hasil panen.


Bagaimana Membaca OLS pada Use Case Ini?

Interpretasi sederhana

- OLS mencoba menarik satu hubungan linear terbaik dari data.
- Jika koefisien suatu fitur positif, kenaikan fitur tersebut cenderung meningkatkan prediksi hasil panen.
- Jika koefisien negatif, kenaikan fitur tersebut cenderung menurunkan prediksi hasil panen.

Kekuatan OLS


- sederhana;
- mudah dijelaskan;
- cocok sebagai model awal atau *baseline*.



Contoh koefisien OLS setelah fitur distandarisasi.


3. Permasalahan OLS: Fitur Saling Berkorelasi

Pada data hasil panen, banyak prediktor saling berhubungan. Kondisi ini disebut **multikolinearitas**.



Permasalahan OLS: Koefisien Bisa Tidak Stabil

Koefisien OLS dapat berubah cukup besar ketika data sedikit berubah. Hal ini menunjukkan bahwa model memang bisa fit pada data latih, tetapi **belum tentu stabil untuk interpretasi dan prediksi baru**.



Makna visualisasi

Setiap box menunjukkan variasi koefisien dari banyak sampel ulang. Semakin lebar variasinya, semakin tidak stabil estimasi koefisien OLS.


Jadi, Mengapa Perlu Shrinkage?

Ide utamanya sederhana

- OLS hanya fokus mengecilkan error.
- OLS tidak menahan koefisien agar tetap kecil.
- Pada data yang kompleks, model bisa menjadi terlalu “percaya diri.”

Shrinkage hadir untuk

- tetap meminimalkan error prediksi;
- sekaligus menambahkan **penalti** pada besar koefisien;
- membuat model lebih stabil dan lebih baik dalam generalisasi.



Variabilitas koefisien OLS dibandingkan Ridge.

4. Ridge Regression

Gagasan utama Ridge

Ridge menggunakan OLS sebagai dasar, lalu menambahkan penalti terhadap **kuadrat koefisien**. Dengan demikian, semua koefisien didorong untuk mengecil.

$$\min_{\beta_0, \beta} \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

- jika $\lambda = 0$, Ridge sama seperti OLS;
- jika λ membesar, penalti makin kuat;
- semua koefisien mengecil, tetapi umumnya **tidak menjadi nol**.


Intuisi Ridge pada Kasus Hasil Panen

Mengapa Ridge membantu?

- saat beberapa fitur sama-sama relevan,
- tetapi saling berkorelasi,
- Ridge membagi pengaruh secara lebih hati-hati.

Pesan sederhana

Ridge berkata: *"Semua fitur boleh tetap masuk, tetapi jangan ada koefisien yang terlalu ekstrem."*



Semua koefisien menyusut bertahap ketika λ membesar.

5. Lasso Regression

Gagasan utama Lasso

Lasso juga berangkat dari OLS, tetapi penalti yang digunakan adalah **jumlah nilai absolut koefisien**. Penalty ini membuat sebagian koefisien dapat menjadi tepat nol.

$$\min_{\beta_0, \beta} \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

- beberapa koefisien menyusut kuat sampai nol;
- model menjadi lebih ringkas;
- Lasso dapat melakukan **seleksi fitur otomatis**.


Intuisi Lasso pada Kasus Hasil Panen

Mengapa Lasso menarik?

- tidak semua fitur selalu penting;
- beberapa fitur mungkin hanya memberi kontribusi kecil;
- Lasso membantu memilih fitur yang paling dominan.


Pesan sederhana

Lasso berkata: *“Jika suatu fitur tidak cukup penting, lebih baik koefisiennya dibuat nol.”*



Beberapa koefisien menjadi nol ketika λ diperbesar.


Efek Seleksi Fitur pada Lasso



Interpretasi

Semakin besar penalti, semakin banyak fitur yang dieliminasi dari model. Karena itu, Lasso sangat berguna saat kita juga ingin menyederhanakan model, bukan hanya meningkatkan kestabilan.

Ringkasan: OLS, Ridge, dan Lasso



Kapan Menggunakan Ridge dan Kapan Menggunakan Lasso?

Gunakan Ridge jika...

- banyak fitur sama-sama penting;
- terdapat multikolinearitas;
- fokus utamanya adalah kestabilan dan akurasi prediksi.

Gunakan Lasso jika...

- ingin model yang lebih ringkas;
- ingin seleksi fitur otomatis;
- diduga hanya sebagian kecil fitur yang dominan.

Kalimat penutup

Pada masalah prediksi hasil panen, Ridge membantu ketika banyak variabel sama-sama relevan, sedangkan Lasso membantu ketika kita juga ingin mengetahui fitur mana yang benar-benar penting.