

Kumpulan Soal Pilihan Ganda: Pengenalan Machine Learning

Materi: Konsep Dasar, Tahapan, Evaluasi, dan Use Case

Sasaran: Mahasiswa Kecerdasan Buatan / Ilmu Komputer

BAGIAN 1: HUBUNGAN AI, MACHINE LEARNING, DAN DATA SCIENCE

Soal 1

Manakah dari pernyataan berikut yang paling tepat menggambarkan relasi hierarkis antara Artificial Intelligence (AI), Machine Learning (ML), dan Data Science (DS)?

- A. AI adalah bagian dari ML, sedangkan ML merupakan bagian dari DS yang berfokus penuh pada statistik deskriptif.
- B. ML adalah subset dari AI yang berfokus pada sistem yang belajar dari data, sedangkan DS adalah bidang luas yang memanfaatkan ML sebagai salah satu alatnya (*tools*).
- C. DS dan AI adalah dua bidang mandiri yang tidak beririsan, sementara ML menjembatani keduanya secara terpisah.
- D. AI, ML, dan DS memiliki ruang lingkup yang sama persis dan hanya dibedakan oleh istilah industri yang digunakannya.

- **Kunci Jawaban:** B
- **Penjelasan:** Sesuai materi Kuliah 09 Halaman 1, AI adalah bidang luas untuk meniru kecerdasan manusia. ML adalah subset dari AI yang belajar dari data tanpa diprogram secara eksplisit. DS adalah bidang pengolahan data untuk menghasilkan *insight* di mana ML menjadi salah satu alatnya (*tools*).

Soal 2

Dalam konteks AI, aktivitas seperti *reasoning*, *planning*, *problem solving*, dan *perception* dikelompokkan sebagai...

- A. Subset langsung dari algoritma pembelajaran terbimbing (*supervised learning*).
- B. Aktivitas khusus dalam Data Science deskriptif.
- C. Kapabilitas bidang luas Artificial Intelligence (AI) untuk meniru kecerdasan manusia.
- D. Tahapan penyesuaian parameter dalam formula $\hat{y} = f(X)$.

- **Kunci Jawaban:** C
- **Penjelasan:** Berdasarkan dokumen Halaman 1, *reasoning*, *planning*, *problem solving*, dan *perception* adalah contoh dari kapabilitas Artificial Intelligence (AI) secara luas.

Soal 3

Seorang praktisi Data Science melakukan pembersihan data (*data cleaning*), visualisasi sebaran data, dan analisis korelasi tanpa melatih model prediktif. Aktivitas ini dikategorikan sebagai...

- A. Machine Learning terapan
- B. Bagian dari cakupan kerja Data Science
- C. Proses *deployment* model
- D. Analisis preskriptif murni

- **Kunci Jawaban:** B
- **Penjelasan:** Data Science mencakup pengumpulan data, pembersihan, analisis, dan visualisasi untuk menghasilkan *insight* (Halaman 1-2). Melatih model ML hanyalah salah satu bagian dari *tools* yang ada di dalamnya.

Soal 4

Tingkatan analitik data yang menjawab pertanyaan "Mengapa hasil panen menurun?" didefinisikan sebagai...

- A. Descriptive Analytics
- B. Diagnostic Analytics
- C. Predictive Analytics
- D. Prescriptive Analytics

- **Kunci Jawaban:** B
- **Penjelasan:** Berdasarkan tabel tingkatan data analytics pada Halaman 2, pertanyaan "Mengapa ini terjadi?" (misalnya: mengapa hasil panen menurun?) merupakan domain dari **Diagnostic Analytics**.

Soal 5

Seorang ahli agronomi ingin merekomendasikan "Waktu tanam optimal dan takaran pupuk terbaik" untuk petani demi memaksimalkan hasil panen musim depan. Analisis ini termasuk dalam tingkatan...

- A. Diagnostic Analytics
- B. Predictive Analytics
- C. Prescriptive Analytics
- D. Descriptive Analytics

- **Kunci Jawaban:** C
- **Penjelasan:** Berdasarkan Halaman 2, pertanyaan "Apa yang sebaiknya dilakukan?" dengan contoh "Waktu tanam optimal" merupakan bentuk **Prescriptive Analytics** karena memberikan rekomendasi tindakan konkret.

Soal 6

Perbedaan mendasar antara *Predictive Analytics* dan *Prescriptive Analytics* terletak pada...

- A. Predictive berfokus pada apa yang telah terjadi, sedangkan Prescriptive berfokus pada penyebab kegagalan sistem.
- B. Predictive memproyeksikan apa yang akan terjadi di masa depan, sedangkan Prescriptive merekomendasikan keputusan atau tindakan terbaik yang harus diambil.
- C. Predictive menggunakan aturan pemrograman tradisional, sedangkan Prescriptive sepenuhnya menggunakan *Unsupervised Learning*.
- D. Predictive tidak memerlukan data historis, sedangkan Prescriptive sangat bergantung pada model regresi linear murni.

- **Kunci Jawaban:** B
- **Penjelasan:** Sesuai Halaman 2, *Predictive* menjawab "Apa yang akan terjadi?" sedangkan *Prescriptive* menjawab "Apa yang sebaiknya dilakukan?" (pemberian solusi/rekomendasi keputusan).

BAGIAN 2: TRADISIONAL VS MACHINE LEARNING & PRINSIP LEARNING

Soal 7

Pendekatan pemrograman tradisional dirasa tidak efektif untuk memecahkan masalah prediksi hasil panen pertanian yang kompleks karena...

- A. Parameter model tradisional terlalu sensitif terhadap perubahan data baru.
- B. Terlalu banyak faktor yang saling berinteraksi secara non-linear sehingga sulit merumuskan aturan (*rules*) eksplisit secara manual.
- C. Pemrograman tradisional membutuhkan memori penyimpanan komputer yang jauh lebih besar daripada ML.
- D. Aturan dalam pemrograman tradisional ditulis secara otomatis oleh komputer sehingga sering tidak konsisten.

- **Kunci Jawaban:** B
- **Penjelasan:** Halaman 2 menjelaskan bahwa pendekatan tradisional sulit membuat aturan pasti karena banyak faktor yang saling berinteraksi, bersifat subjektif, dan tidak konsisten antar pengamat. ML sebaliknya dapat menangkap pola kompleks dan non-linear tersebut secara objektif.

Soal 8

Pada pemrograman tradisional, yang bertindak sebagai **input** bagi komputer untuk menghasilkan **output** adalah...

- A. Data dan contoh output dari sistem.

B. Data dan aturan (*rules*) eksplisit yang ditulis oleh programmer.

C. Model matematika hasil penyesuaian parameter.

D. Prediksi kesalahan (*error*) hasil iterasi data.

- **Kunci Jawaban:** B

- **Penjelasan:** Berdasarkan tabel perbandingan pada Halaman 4, pemrograman tradisional menerima input berupa **Data + aturan eksplisit** untuk menghasilkan output/keputusan.

Soal 9

Dalam Machine Learning, komputer menerima **Data + contoh output** untuk menghasilkan...

A. Program komputer berupa aturan-aturan statis.

B. Prediksi atau keputusan berdasarkan model yang mempelajari pola data secara mandiri.

C. Dataset baru yang telah dibersihkan secara otomatis.

D. Parameter bobot yang ditentukan secara acak oleh programmer.

- **Kunci Jawaban:** B

- **Penjelasan:** Pada Machine Learning, inputnya adalah **Data + contoh output** (untuk supervised), menghasilkan **prediksi/keputusan dari model** yang terbentuk dari hasil belajar pola sendiri (Halaman 4).

Soal 10

Konsep dasar pembelajaran (*learning*) dalam Machine Learning melibatkan tiga komponen utama, yaitu...

A. Aturan eksplisit, data uji, dan visualisasi grafik.

B. Algoritma pencarian, memori penyimpanan, dan server deployment.

C. Data, Model, dan Penyesuaian Parameter.

D. Segmentasi, Klasifikasi, dan Regresi.

- **Kunci Jawaban:** C

- **Penjelasan:** Berdasarkan dokumen Halaman 3, konsep utama pembelajaran dirumuskan sebagai:

LEARNING = DATA + MODEL + PENYESUAIAN PARAMETER

Soal 11

Formula model matematika yang memetakan fitur input X menuju prediksi target diwakili oleh persamaan...

A. $y = f(\hat{y})$

B. $\hat{y} = f(X)$

C. $\text{Error} = f(y) - X$

D. $X = f(y)$

- **Kunci Jawaban:** B

- **Penjelasan:** Formula pemetaan fitur X ke estimasi nilai prediksi $\hat{y}$ direpresentasikan dengan persamaan $\hat{y} = f(X)$ (Halaman 3).

Soal 12

Di bawah ini, manakah formula yang tepat untuk merepresentasikan nilai kesalahan (*Loss/Error*) prediksi pada tiap instansi data?

A. $\text{Error} = \hat{y} - X$

B. $\text{Error} = y - \hat{y}$

C. $\text{Error} = f(X) - y^2$

D. $\text{Error} = X \cdot w$

- **Kunci Jawaban:** B

- **Penjelasan:** Berdasarkan Halaman 3, nilai error didefinisikan sebagai selisih antara nilai target sebenarnya (y) dan nilai prediksi ($\hat{y}$), yaitu: $\text{Error} = y - \hat{y}$.

Soal 13

Bagaimana hubungan kerja antara proses penyesuaian parameter (*parameter adjustment*) dengan nilai *error* selama pelatihan model ML?

- A. Parameter model disesuaikan secara berkala untuk memaksimalkan nilai *error*.
- B. Nilai *error* diabaikan demi mendapatkan parameter model yang stabil dan linear.
- C. Parameter model disesuaikan secara berulang (*iterative*) guna meminimalkan nilai *error* prediksi.
- D. Parameter disetel secara manual oleh programmer ketika nilai *error* mendekati angka nol.

- **Kunci Jawaban:** C

- **Penjelasan:** Tujuan dari proses learning adalah meminimalkan *error*. Hal ini dilakukan dengan cara melatih model pada data training, menghitung error, kemudian menyesuaikan parameter model secara otomatis untuk meminimalkan error tersebut (Halaman 3).

BAGIAN 3: JENIS-JENIS LEARNING DAN USE CASE NYATA

Soal 14

Diberikan representasi matematika: $(X, y) \rightarrow \text{Model} \rightarrow \hat{y}$. Skema tersebut merepresentasikan jenis pembelajaran...

- A. Unsupervised Learning
- B. Supervised Learning
- C. Reinforcement Learning
- D. Semi-supervised Clustering

- **Kunci Jawaban:** B

- **Penjelasan:** Skema pemetaan dari data fitur X dan target berlabel y menjadi model untuk menghasilkan prediksi $\hat{y}$ adalah karakteristik dari **Supervised Learning** (Halaman 4).

Soal 15

Manakah dari kasus berikut yang merupakan contoh penerapan *Unsupervised Learning*?

- A. Memprediksi harga rumah di wilayah perkotaan berdasarkan luas tanah dan jumlah kamar.
- B. Mengelompokkan wilayah pertanian berdasarkan karakteristik kesuburan tanah tanpa label sebelumnya.
- C. Mengklasifikasikan email masuk sebagai kategori spam atau bukan spam.
- D. Memprogram agen robotik untuk menemukan rute terpendek di labirin menggunakan *reward*.

- **Kunci Jawaban:** B

- **Penjelasan:** Unsupervised learning belajar dari data tanpa label dengan tujuan mengelompokkan atau menyederhanakan data. Mengelompokkan wilayah pertanian tanpa label merupakan aplikasi clustering (Unsupervised) (Halaman 4-5).

Soal 16

Komponen utama dalam *Reinforcement Learning* yang bertindak sebagai pengambil keputusan (*decision maker*) dan merespons umpan balik (*reward*) dari lingkungan disebut...

- A. Target
- B. Environment
- C. Agent
- D. Feature

- **Kunci Jawaban:** C

- **Penjelasan:** Dalam konsep Reinforcement Learning (Halaman 5), **Agent** bertindak sebagai pengambil keputusan yang berinteraksi dengan lingkungan (*Environment*) untuk memaksimalkan akumulasi *reward*.

Soal 17

Sistem navigasi otomatis pada kendaraan otonom yang mempelajari kapan harus mengerem atau mempercepat laju kendaraan melalui simulasi jatuh bangun (*trial-and-error*) menerapkan metode...

- A. Supervised Regression
- B. Dimension Reduction
- C. Reinforcement Learning
- D. Unsupervised Clustering

- **Kunci Jawaban:** C
- **Penjelasan:** Pembelajaran yang berinteraksi langsung dengan lingkungan dengan memanfaatkan konsep aksi dan umpan balik (*reward/penalty*) adalah **Reinforcement Learning** (Halaman 5).

Soal 18

Manakah dari kelompok aplikasi berikut yang seluruhnya dikategorikan sebagai *Supervised Learning*?

- A. Segmentasi pelanggan, prediksi harga saham, pengelompokan tanaman.
- B. Klasifikasi penyakit kanker, prediksi hasil panen, taksiran harga mobil bekas.
- C. Navigasi robot otonom, sistem rekomendasi adaptif, reduksi dimensi data.
- D. Deteksi spam email, pengelompokan jenis batuan bumi, segmentasi pasar.

- **Kunci Jawaban:** B
- **Penjelasan:** Klasifikasi penyakit kanker (klasifikasi), prediksi hasil panen (regresi), dan taksiran harga mobil bekas (regresi) semuanya memiliki target berlabel (y), sehingga termasuk Supervised Learning (Halaman 4).

Soal 19

Sistem rekomendasi adaptif (seperti rekomendasi video atau produk yang berubah dinamis mengikuti kepuasan langsung pengguna) dan *game playing* (seperti AlphaGo) umumnya dikembangkan menggunakan pendekatan...

- A. Batch Supervised Learning
- B. Unsupervised Association Rules
- C. Reinforcement Learning

D. Linear Regression

- **Kunci Jawaban:** C
- **Penjelasan:** Sesuai Halaman 5, sistem rekomendasi adaptif dan *game playing* (AlphaGo, DQN) merupakan contoh penerapan nyata dari **Reinforcement Learning**.

BAGIAN 4: TAHAPAN WORKFLOW MACHINE LEARNING

Soal 20

Langkah paling awal yang krusial sebelum mengumpulkan data atau memilih algoritma Machine Learning adalah...

A. Membagi data menjadi training, validation, dan testing set.

B. Melakukan penyesuaian parameter model $\hat{y} = f(X)$.

C. Menentukan masalah, tujuan, tipe masalah (regresi/klasifikasi), dan metrik keberhasilan (*Problem Formulation*).

D. Melakukan normalisasi data dan menangani pencilan data (*noise*).

- **Kunci Jawaban:** C
- **Penjelasan:** Tahap pertama yang wajib dilakukan adalah *Problem Formulation* (Menentukan masalah dan tujuan), yang mendefinisikan apa yang ingin diprediksi dan jenis masalahnya (Halaman 5-6).

Soal 21

Mengapa proses pemilihan fitur yang relevan (*feature selection*) dilakukan pada tahap *Data Preparation*?

A. Agar model dapat langsung dilaunching ke server production tanpa ditraining terlebih dahulu.

B. Untuk memastikan model mempelajari pola dari fitur-fitur penting yang benar-benar memengaruhi target dan mengesampingkan *noise*.

C. Untuk mengubah tipe masalah dari regresi menjadi klasifikasi biner secara otomatis.

D. Agar pembagian porsi data training berubah secara acak tanpa aturan proporsi.

- **Kunci Jawaban:** B
- **Penjelasan:** Halaman 6 menjelaskan bahwa *Data Preparation* mencakup pembersihan data dari *noise* dan pemilihan fitur (*feature selection*) agar model berjalan efisien dengan hanya menggunakan fitur-fitur yang relevan.

Soal 22

Pembagian dataset menjadi subset *Training*, *Validation*, dan *Test set* memiliki tujuan yang berbeda. Fungsi utama dari *Validation set* adalah...

- A. Melatih parameter internal model seperti bobot (w).
- B. Menilai performa final secara mutlak pada data riil yang belum pernah dilihat sama sekali.
- C. Memilih model terbaik atau menyetel nilai parameter eksternal (*hyperparameter*).
- D. Melakukan visualisasi performa akhir kepada pengguna.

- **Kunci Jawaban:** C

- **Penjelasan:** Sesuai tabel pada Halaman 6, *Validation set* digunakan untuk memilih model atau mencari konfigurasi *hyperparameter* terbaik sebelum diuji pada data tes akhir (*Test set*).

Soal 23

Seorang mahasiswa membagi datasetnya menjadi 70% Training, 15% Validation, dan 15% Testing. Pembagian proporsi ini...

- A. Salah, karena data training harus selalu tepat berjumlah 90% dari keseluruhan data.
- B. Benar dan berada di dalam rentang proporsi umum (60-80% Training, 10-20% Validation, 10-20% Testing).
- C. Tidak dianjurkan karena porsi data validation harus selalu lebih besar daripada data testing.
- D. Berisiko tinggi menyebabkan model mengalami overfitting pada data training.

- **Kunci Jawaban:** B

- **Penjelasan:** Pembagian tersebut ideal dan lazim digunakan di mana proporsi umum yang direkomendasikan adalah Training (60-80%), Validation (10-20%), dan Testing (10-20%) (Halaman 6).

Soal 24

Apa perbedaan mendasar dalam penggunaan *Validation set* dan *Test set*?

- A. *Validation set* digunakan saat training untuk memilih model, sedangkan *Test set* digunakan di akhir untuk menilai performa final secara objektif pada data baru.
- B. *Validation set* digunakan untuk melatih bobot model, sedangkan *Test set* digunakan untuk mendeteksi data yang hilang (*missing values*).
- C. *Validation set* diuji setelah model di-*deploy*, sedangkan *Test set* diuji sebelum model dilatih.
- D. Tidak ada perbedaan, keduanya merujuk pada kumpulan data yang sama dan dapat digunakan bergantian secara bebas.

- **Kunci Jawaban:** A

- **Penjelasan:** Berdasarkan ringkasan intuisi pada Halaman 6: "*Training untuk belajar, validation untuk memilih (model/hyperparameter), testing untuk menguji (secara final pada data baru)*".

Soal 25

Setelah model Machine Learning selesai dilatih, diuji, dan kinerjanya dinyatakan layak, model tersebut diintegrasikan ke dalam sistem aplikasi nyata (seperti dashboard prediksi petani). Proses ini disebut...

- A. Problem Formulation
- B. Data Preprocessing
- C. Deployment
- D. Concept Drift

- **Kunci Jawaban:** C
- **Penjelasan:** *Deployment* didefinisikan sebagai tahapan di mana model dipindahkan dan digunakan pada lingkungan operasional nyata untuk melayani pengguna (Halaman 6).

Soal 26

Fenomena di mana pola data baru di lapangan mengalami perubahan karakteristik seiring berjalannya waktu, sehingga akurasi prediksi model perlahan menurun disebut...

- A. Underfitting
- B. Concept Drift
- C. Hyperparameter Tuning
- D. Missing Values

- **Kunci Jawaban:** B
- **Penjelasan:** Halaman 7 menyatakan bahwa pemantauan (*monitoring*) model diperlukan karena data baru bisa berubah polanya, sebuah fenomena yang dikenal sebagai **Concept Drift**.

Soal 27

Bagaimana solusi terbaik untuk menangani terjadinya degradasi performa model akibat *concept drift* di lingkungan produksi?

- A. Memperbesar kapasitas penyimpanan server tempat model di-*deploy*.
- B. Mengubah seluruh masalah regresi menjadi masalah klasifikasi biner.
- C. Melakukan *monitoring* kontinu dan memperbarui (*re-train*) model secara berkala dengan data historis terbaru.
- D. Mengabaikan data baru dan memaksa model menggunakan data latih pertama yang statis.

- **Kunci Jawaban:** C
- **Penjelasan:** Berdasarkan Halaman 7, karena performa model bisa menurun seiring waktu akibat pergeseran data, model perlu dipantau secara ketat dan diperbarui (*re-train*) secara berkala dengan data yang representatif.

BAGIAN 5: EVALUASI MODEL REGRESI & PERHITUNGAN METRIK

Soal 28

Tujuan utama melakukan evaluasi model setelah fase pelatihan selesai adalah untuk...

- A. Memastikan akurasi pada data training mencapai nilai sempurna (error 0%).
- B. Mengukur kualitas prediksi model pada data baru, mendeteksi underfitting/overfitting, dan memastikan kelayakan model sebelum digunakan.
- C. Menulis ulang aturan-aturan eksplisit yang gagal dipelajari oleh programmer.
- D. Menghilangkan fitur-fitur yang memiliki nilai korelasi linear yang terlalu kuat.

- **Kunci Jawaban:** B
- **Penjelasan:** Evaluasi bertujuan mengukur kualitas prediksi pada data baru (generalisasi), membandingkan beberapa model alternatif, mendeteksi gejala underfitting atau overfitting, serta memastikan model layak digunakan (Halaman 7).

Soal 29

Diberikan persamaan metrik berikut:

$$\frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Persamaan tersebut merupakan rumus perhitungan untuk metrik...

- A. Mean Squared Error (MSE)
- B. Root Mean Squared Error (RMSE)
- C. Mean Absolute Error (MAE)
- D. Coefficient of Determination (R^2)

- **Kunci Jawaban:** C
- **Penjelasan:** Rumus tersebut menjumlahkan nilai selisih absolut antara nilai aktual y_i dan nilai prediksi $\hat{y}_i$, lalu membaginya dengan jumlah sampel n , yang merupakan rumus dari **Mean Absolute Error (MAE)** (Halaman 7).

Soal 30

Mengapa metrik MSE (Mean Squared Error) memberikan nilai penalti yang jauh lebih besar pada kesalahan (*error*) yang berukuran besar dibandingkan MAE?

- A. Karena MSE melakukan pembagian nilai error dengan jumlah data secara eksponensial.
- B. Karena selisih antara nilai aktual dan nilai prediksi pada MSE dipangkatkan dua (dikuadratkan).

C. Karena MSE membatasi nilai kesalahan hanya pada rentang nilai antara 0 dan 1.

D. Karena MSE mengabaikan nilai negatif dari hasil kalkulasi error.

- **Kunci Jawaban:** B

- **Penjelasan:** MSE dihitung dengan mengkuadratkan selisih $(y_i - \hat{y}_i)^2$, sehingga kesalahan prediksi yang besar akan menghasilkan penalti kuadratis yang sangat besar dibandingkan kesalahan yang bernilai kecil (Halaman 7).

Soal 31

Di antara metrik-metrik regresi berikut, metrik yang mengembalikan satuan nilai kesalahan prediksi ke dalam satuan asli target data (sehingga lebih mudah diinterpretasikan oleh pengguna non-teknis) adalah...

A. Mean Squared Error (MSE)

B. Coefficient of Determination (R^2)

C. Root Mean Squared Error (RMSE)

D. Mean Absolute Percentage Error (MAPE)

- **Kunci Jawaban:** C

- **Penjelasan:** RMSE didefinisikan sebagai akar kuadrat dari MSE. Pengakaran ini

mengembalikan satuan pengukuran error ke satuan semula yang sama dengan target y (misalnya dalam satuan ton/ha atau rupiah), memudahkan interpretasi (Halaman 7 & 12).

Soal 32

Seorang peneliti pertanian melatih model regresi untuk memprediksi hasil panen padi. Hasil evaluasi menunjukkan nilai Koefisien Determinasi (R^2) sebesar 0.85. Makna dari nilai ini adalah...

A. Model melakukan kesalahan prediksi rata-rata sebesar 85% dari total panen sesungguhnya.

B. Sebesar 85% variansi dari data hasil panen padi dapat dijelaskan dengan baik oleh fitur-fitur dalam model regresi tersebut.

C. Akurasi klasifikasi model dalam membedakan padi sehat dan sakit mencapai nilai 85%.

D. Model mengalami gejala overfitting sebesar 85% pada data validasi.

- **Kunci Jawaban:** B

- **Penjelasan:** Koefisien determinasi (R^2) mengukur proporsi variansi data target yang berhasil dijelaskan oleh fitur-fitur prediktif di dalam model (Halaman 7). Nilai 0.85 berarti 85% variabilitas data dijelaskan oleh model.

Soal 33

Diberikan data aktual hasil panen padi $y = [6.0, 5.0]$ ton/ha, dan hasil prediksi model $\hat{y} = [5.5, 3.0]$ ton/ha. Berapakah nilai Mean Absolute Error (MAE) dari prediksi tersebut?

- A. 1.00 ton/ha
- B. 1.25 ton/ha
- C. 2.12 ton/ha
- D. 2.50 ton/ha

- **Kunci Jawaban:** B

- **Penjelasan:** Error 1: $|6.0 - 5.5| = 0.5$

Error 2: $|5.0 - 3.0| = 2.0$

$$\text{MAE} = \frac{0.5+2.0}{2} = 1.25 \text{ ton/ha (Halaman 11).}$$

Soal 34

Berdasarkan data pada Soal 33 ($y = [6.0, 5.0]$ dan $\hat{y} = [5.5, 3.0]$), hitunglah nilai Mean Squared Error (MSE) yang dihasilkan!

- A. 1.25
- B. 2.125
- C. 1.460
- D. 4.250

- **Kunci Jawaban:** B

- **Penjelasan:** Kuadrat Error 1: $(6.0 - 5.5)^2 = 0.25$

Kuadrat Error 2: $(5.0 - 3.0)^2 = 4.00$

$$\text{MSE} = \frac{0.25+4.00}{2} = 2.125 \text{ (Halaman 11).}$$

Soal 35

Berdasarkan nilai MSE yang diperoleh dari Soal 34 ($\text{MSE} = 2.125$), berapakah nilai Root Mean Squared Error (RMSE) model tersebut?

- A. ≈ 1.25 ton/ha
- B. ≈ 1.46 ton/ha
- C. ≈ 2.12 ton/ha

D. ≈ 2.42 ton/ha

- **Kunci Jawaban:** B

- **Penjelasan:** $RMSE = \sqrt{MSE} = \sqrt{2.125} \approx 1.46$ ton/ha (Halaman 11).

Soal 36

Berdasarkan data dari Soal 33, hitunglah nilai persentase kesalahan prediksi atau Mean Absolute Percentage Error (MAPE)!

A. $\approx 12.5\%$

B. $\approx 24.2\%$

C. $\approx 31.6\%$

D. $\approx 50.0\%$

- **Kunci Jawaban:** B

- **Penjelasan:**
$$MAPE = \frac{1}{2} \left(\frac{|6.0-5.5|}{6.0} + \frac{|5.0-3.0|}{5.0} \right) \times 100\%$$
$$MAPE = \frac{1}{2} \left(\frac{0.5}{6.0} + \frac{2.0}{5.0} \right) \times 100\% = \frac{1}{2} (0.0833 + 0.40) \times 100\% = 0.2416 \times 100\% \approx 24.2\%$$
(Halaman 11).

Soal 37

Dalam mengomunikasikan performa model prediksi hasil panen padi kepada kelompok tani tradisional, metrik manakah yang paling mudah dipahami secara intuitif oleh mereka?

A. MSE karena penaltinya besar

B. R-squared (R^2) karena berupa nilai statistik teoretis

C. MAPE karena dinyatakan langsung dalam bentuk persentase kesalahan rata-rata

D. MAE karena tidak menggunakan fungsi kuadrat dalam kalkulasinya

- **Kunci Jawaban:** C

- **Penjelasan:** Sesuai tabel interpretasi pada Halaman 12, metrik MAPE (persentase error) adalah yang paling mudah dikomunikasikan secara langsung kepada petani atau khalayak umum karena disajikan dalam bentuk persentase kesalahan sederhana.

BAGIAN 6: EVALUASI MODEL KLASIFIKASI

Soal 38

Metrik evaluasi klasifikasi yang mengukur proporsi data yang diprediksi benar secara

keseluruhan (baik positif maupun negatif) dari total seluruh data uji disebut...

- A. Precision
- B. Recall
- C. Akurasi
- D. F1-score

- **Kunci Jawaban:** C
- **Penjelasan:** Berdasarkan Halaman 8, **Akurasi** didefinisikan sebagai proporsi prediksi benar secara keseluruhan terhadap total populasi data uji.

Soal 39

Sebuah model klasifikasi citra daun mendeteksi penyakit tanaman. Metrik yang menjawab pertanyaan: "Dari semua daun yang **diprediksi sakit** oleh model, berapa banyak daun yang **benar-benar sakit** secara aktual?" adalah...

- A. Recall
- B. Precision
- C. F1-score
- D. Confusion Matrix

- **Kunci Jawaban:** B
- **Penjelasan:** Berdasarkan definisi pada Halaman 8, **Precision** mengukur ketepatan prediksi positif model: "dari yang diprediksi positif, berapa yang benar-benar positif".

Soal 40

Model klasifikasi medis digunakan untuk memprediksi pasien diabetes. Dokter menekankan pentingnya mendeteksi sebanyak mungkin pasien sakit yang sebenarnya agar tidak terlewat mendapat perawatan. Metrik klasifikasi utama yang harus dioptimalkan dalam skenario ini adalah...

- A. Precision
- B. Recall
- C. Akurasi
- D. MAPE

- **Kunci Jawaban:** B
- **Penjelasan:** Sesuai penjelasan Halaman 8, **Recall** mengukur seberapa banyak kasus positif aktual yang berhasil ditemukan oleh model. Pada kasus deteksi penyakit, recall sangat krusial agar kasus positif sakit tidak banyak terlewat (meminimalkan *false negative*).

Soal 41

Metrik *F1-score* ideal digunakan untuk mengevaluasi performa model klasifikasi ketika...

- A. Kita ingin menyeimbangkan kinerja model antara metrik *Precision* dan *Recall* (terutama pada dataset yang tidak seimbang).
- B. Kita hanya peduli pada nilai prediksi negatif yang benar secara mutlak.
- C. Target variabel yang diprediksi berupa nilai kontinu numerik seperti harga rumah.
- D. Kita ingin mengukur proporsi variansi data yang dijelaskan oleh fitur model.

- **Kunci Jawaban:** A
- **Penjelasan:** Sesuai Halaman 8, *F1-score* adalah rata-rata harmonik antara *precision* dan *recall*, berguna untuk memberikan evaluasi tunggal yang seimbang atas kedua aspek tersebut.

Soal 42

Tabel perbandingan dua dimensi yang menyajikan performa klasifikasi secara detail dengan menyandingkan data aktual (baris) dan data hasil prediksi model (kolom) disebut...

- A. Regression Matrix
- B. Confusion Matrix
- C. Decision Tree
- D. Dispersion Table

- **Kunci Jawaban:** B
- **Penjelasan:** Berdasarkan tabel pada Halaman 8, **Confusion Matrix** didefinisikan sebagai tabel perbandingan prediksi vs aktual per kelas.

BAGIAN 7: UNDERFITTING, OVERFITTING, DAN BALANCED MODEL

Soal 43

Sebuah model regresi linear dicoba untuk memetakan hubungan dataset yang polanya sangat non-linear dan bergelombang. Model tersebut menghasilkan nilai *error* yang sangat tinggi baik pada data training maupun data testing. Kondisi ini disebut...

- A. Overfitting
- B. Underfitting
- C. Balanced Model
- D. Concept Drift

- **Kunci Jawaban:** B
- **Penjelasan:** Sesuai Halaman 8, *Underfitting* ditandai dengan model yang terlalu sederhana, tidak mampu menangkap pola penting pada data, serta menghasilkan *error training* dan *testing* yang sama-sama tinggi.

Soal 44

Karakteristik utama dari model yang mengalami masalah **Overfitting** adalah...

- A. Performa model buruk pada data training, namun sangat baik pada data testing.
- B. Performa model sangat baik pada data training (error sangat rendah), namun buruk pada data validation maupun data testing.
- C. Model memiliki struktur yang terlalu sederhana dengan parameter yang sedikit.
- D. Model berhasil menyelaraskan parameter secara seimbang antara akurasi dan generalisasi.

- **Kunci Jawaban:** B
- **Penjelasan:** Berdasarkan Halaman 8-9, *Overfitting* ditandai dengan model terlalu kompleks, sangat baik pada training set, namun buruk saat dihadapkan pada validation/test set karena model menghafal *noise* sebagai pola data.

Soal 45

Di bawah ini yang merupakan salah satu penyebab utama terjadinya gejala *overfitting* pada pelatihan model Machine Learning adalah...

- A. Data training yang digunakan terlalu banyak dan variatif.
- B. Struktur arsitektur model terlalu sederhana dan kaku.
- C. Model memiliki terlalu banyak parameter bebas sedangkan jumlah data training sangat sedikit.
- D. Penggunaan data validation yang proporsinya mencapai 50%.

- **Kunci Jawaban:** C
- **Penjelasan:** Berdasarkan materi Halaman 9, penyebab umum *overfitting* adalah terlalu banyak parameter (model terlalu kompleks) dan data training terlalu sedikit, sehingga model menangkap *noise* sebagai pola.

Soal 46

Manakah kondisi kompleksitas model dan nilai error yang benar terkait **Balanced Model** (Model Seimbang)?

- A. Kompleksitas Rendah; Train Error Tinggi; Test Error Tinggi.
- B. Kompleksitas Sedang; Train Error Rendah; Test Error Rendah.
- C. Kompleksitas Tinggi; Train Error Sangat Rendah; Test Error Tinggi.
- D. Kompleksitas Tinggi; Train Error Tinggi; Test Error Rendah.

- **Kunci Jawaban:** B
- **Penjelasan:** Berdasarkan tabel perbandingan kondisi pada Halaman 9:
 - Underfitting: Kompleksitas Rendah, Train Error Tinggi, Test Error Tinggi.
 - Balanced: Kompleksitas Sedang, Train Error Rendah, Test Error Rendah.
 - Overfitting: Kompleksitas Tinggi, Train Error Sangat Rendah, Test Error Tinggi.

Soal 47

Tujuan utama dari perancangan sistem Machine Learning adalah membangun model yang seimbang antara...

- A. Kompleksitas model dan jumlah memori komputasi yang digunakan.
- B. Kecepatan pengolahan data dan metode visualisasi grafis.
- C. Akurasi performa pada data latih dan kemampuan generalisasi pada data baru.
- D. Pemrograman tradisional dengan penyesuaian parameter manual.

- **Kunci Jawaban:** C
- **Penjelasan:** Tujuan utama ML adalah menemukan model yang seimbang antara akurasi (pada data latih) dan kemampuan generalisasi (kemampuan memprediksi dengan baik pada data baru yang belum pernah dilihat) (Halaman 9).

Soal 48

Dalam memilih model terbaik, manakah alur kerja yang direkomendasikan dalam slide perkuliahan?

- A. Gunakan model yang paling kompleks sejak awal, lalu evaluasi performanya langsung pada test set tanpa validation set.
- B. Mulai dari model sederhana, evaluasi dengan validation set, bandingkan beberapa model/parameter, pilih model terbaik pada data validasi, dan gunakan test set hanya untuk evaluasi akhir.
- C. Latih model pada training set, pilih model yang menghasilkan akurasi paling sempurna pada training set tersebut, lalu deploy.
- D. Ubah hyperparameter model terus-menerus menggunakan test set agar didapatkan akurasi pengujian setinggi mungkin.

- **Kunci Jawaban:** B
- **Penjelasan:** Sesuai petunjuk Halaman 9 bagian 9.5 "Cara Memilih Model", langkah yang benar adalah memulai dari model sederhana, evaluasi dengan validation set, bandingkan parameter, pilih model terbaik pada data validasi, dan gunakan test set eksklusif untuk evaluasi akhir.

BAGIAN 8: PENERAPAN REGRESI UNTUK PREDIKSI HASIL PANEN

Soal 49

Dalam model prediksi hasil panen padi, fitur input X yang digunakan dan target output y yang ingin diprediksi secara berurutan adalah...

- A. X : Hasil panen (ton/ha) ; y : Jenis pupuk dan curah hujan.

B. X : Jenis tanah dan kelembaban ; y : Klasifikasi padi sakit atau sehat.

C. X : Curah hujan, suhu, kelembaban tanah, pupuk ; y : Hasil panen (ton/ha).

D. X : Nama petani ; y : Luas wilayah pertanian global.

- **Kunci Jawaban:** C

- **Penjelasan:** Berdasarkan use case nyata di Halaman 10, fitur input X mencakup faktor lingkungan seperti curah hujan, suhu, kelembaban tanah, dan penggunaan pupuk. Target output y adalah nilai numerik kontinu berupa hasil panen (ton/ha).

Soal 50

Mengapa kasus prediksi hasil panen padi berdasarkan curah hujan dan penggunaan pupuk dikategorikan sebagai masalah *supervised learning* jenis **regresi**?

A. Karena model dilatih menggunakan data tanpa label target.

B. Karena target variabel yang diprediksi berupa nilai biner (sakit vs sehat).

C. Karena target variabel yang diprediksi bernilai numerik kontinu (kontinu/riil).

D. Karena model menggunakan konsep *reward* dan *penalty* dari lingkungan tanam.

- **Kunci Jawaban:** C

- **Penjelasan:** Masalah ini adalah supervised learning jenis regresi karena target variabel yang diprediksi berupa nilai kontinu atau numerik (hasil panen dalam satuan ton/ha) (Halaman 10).