

Latihan Soal Pilihan Ganda: Supervised & Unsupervised Learning

Topik: Studi Kasus Analisis dan Prediksi Produktivitas Padi (Kuliah 10)

Pengampu: Yeni Herdiyeni, IPB University

Jumlah Soal: 50 Soal Pilihan Ganda (PG) beserta Kunci Jawaban & Pembahasan

Bagian I: Soal Pilihan Ganda (1 - 50)

1. Mengapa pendekatan pemrograman tradisional (berbasis aturan manual) sulit diterapkan untuk memprediksi hasil panen padi pada kondisi dunia nyata?

- A. Aturan manual membutuhkan daya komputasi yang jauh lebih besar daripada algoritma machine learning.
- B. Hubungan antarvariabel pertanian bersifat kompleks, non-linear, dan memiliki interaksi yang saling memengaruhi.
- C. Pendekatan tradisional tidak mendukung penggunaan variabel numerik kontinu seperti curah hujan dan suhu.
- D. Aturan manual selalu menghasilkan nilai prediksi yang bias terhadap nilai rata-rata sampel.

2. Jika seorang peneliti ingin mengelompokkan lahan pertanian ke dalam beberapa zona berdasarkan tingkat kesuburan tanpa menentukan target produktivitas terlebih dahulu, paradigma machine learning apa yang paling tepat digunakan?

- A. Supervised Learning
- B. Unsupervised Learning
- C. Reinforcement Learning
- D. Semi-Supervised Learning

3. Dalam implementasi sistem irigasi otomatis, komputer belajar menentukan kapan harus menyiram air berdasarkan umpan balik berupa efisiensi air dan kesehatan tanaman. Hal ini merupakan contoh dari...

- A. Supervised Learning
- B. Unsupervised Learning
- C. Reinforcement Learning
- D. Evolutionary Learning

4. Manakah di antara pilihan berikut yang merupakan variabel target (y) dalam use case prediksi produktivitas padi berdasarkan materi Kuliah 10?

- A. Jumlah pupuk (kg/ha)
- B. Hasil panen (ton/ha)
- C. Curah hujan (mm)
- D. Luas lahan (ha)

5. Apa risiko terbesar dari melakukan pemodelan machine learning langsung tanpa melalui tahapan Exploratory Data Analysis (EDA)?

- A. Model akan secara otomatis menolak data baru yang masuk saat fase testing.
- B. Waktu komputasi pelatihan model akan meningkat hingga sepuluh kali lipat.
- C. Model dapat belajar dari data yang salah, terganggu oleh pencilan (outlier), atau gagal menangkap relasi non-linear.
- D. Algoritma regresi tidak dapat dijalankan karena data belum dikonversi menjadi biner.

6. Berdasarkan temuan EDA pada variabel curah hujan, data menunjukkan distribusi yang tidak simetris atau condong (*skewed*). Langkah penanganan apa yang paling direkomendasikan sebelum pemodelan?

- A. Menghapus seluruh data curah hujan yang berada di luar nilai median.
- B. Melakukan penskalaan (*scaling*) atau transformasi fitur (seperti *log transform*).
- C. Mengubah variabel curah hujan menjadi variabel target baru.
- D. Mengganti semua nilai curah hujan yang bernilai tinggi dengan nilai rata-rata.

7. Hubungan antara curah hujan dan hasil panen padi ternyata tidak linear sempurna; curah hujan yang terlampau tinggi justru menurunkan produktivitas. Keputusan pemodelan apa yang harus diambil berdasarkan fakta ini?

- A. Menolak variabel curah hujan dan menghapusnya dari daftar fitur input.
- B. Menambahkan fitur kuadrat ($rainfall^2$) ke dalam model regresi.
- C. Menggunakan regresi linear sederhana tanpa modifikasi fitur apa pun.
- D. Mengubah tipe data hasil panen menjadi kategorikal diskrit.

8. Selama proses analisis, ditemukan beberapa entitas data dengan hasil panen mendekati nol. Apa tindakan terbaik yang harus diambil oleh seorang data scientist?

- A. Langsung menghapus data tersebut karena dipastikan merupakan kesalahan input (*data entry error*).
- B. Mengganti nilai mendekati nol tersebut dengan nilai rata-rata hasil panen keseluruhan agar distribusi menjadi normal.
- C. Memeriksa makna domain terlebih dahulu, karena nilai mendekati nol tersebut bisa merepresentasikan kasus nyata gagal panen.
- D. Melakukan transformasi kuadratik khusus pada target hasil panen untuk menyembunyikan nilai tersebut.

9. Bagaimana peran analisis korelasi antarvariabel dalam tahapan EDA membantu proses modeling?

- A. Menentukan hubungan sebab-akibat (kausalitas) mutlak antarvariabel input.
- B. Memberikan indikasi awal kedekatan hubungan antarfitur dengan target sebagai dasar pemilihan fitur (*feature selection*).
- C. Menjamin nilai akurasi model regresi akan mencapai 100%.
- D. Mengeliminasi kebutuhan akan proses normalisasi data numerik.

10. Jika visualisasi EDA menunjukkan adanya korelasi yang sangat lemah antara variabel suhu dengan hasil panen, keputusan penyederhanaan model apa yang paling rasional?

- A. Tetap mempertahankan variabel suhu dan membuat fitur kubik ($temperature^3$).
- B. Melakukan eliminasi fitur (*feature selection*) agar model tidak terlalu kompleks.
- C. Mengganti target hasil panen dengan variabel suhu.
- D. Melakukan duplikasi data suhu untuk memperkuat korelasinya secara artifisial.

11. Proses membentuk fitur baru agar menjadi lebih representatif bagi model dengan cara memasukkan pemahaman domain ke dalam data disebut...

- A. Data Collection
- B. Feature Engineering
- C. Model Evaluation
- D. Hyperparameter Tuning

12. Formula manakah di bawah ini yang merepresentasikan pembuatan fitur rasio efisiensi penggunaan pupuk per satuan luas lahan?

- A. $fertilizer_per_area = fertilizer \times land_area$
- B. $fertilizer_per_area = \frac{fertilizer}{land_area}$
- C. $fertilizer_per_area = fertilizer - land_area$
- D. $fertilizer_per_area = \frac{land_area}{fertilizer}$

13. Perhatikan potongan kode berikut:

```
df["rainfall_category"] = pd.cut(
    df["rainfall"],
    bins=[-np.inf, 140, 220, np.inf],
    labels=["rendah", "sedang", "tinggi"]
)
```

Jika sebuah area memiliki curah hujan sebesar 135 mm , maka area

tersebut akan masuk ke dalam kategori...

- A. rendah
- B. sedang
- C. tinggi
- D. netral

14. Berdasarkan potongan kode pada Soal 13, jika curah hujan suatu area bernilai 180 mm , kategori yang diberikan oleh fungsi `pd.cut` adalah...

- A. rendah
- B. sedang
- C. tinggi
- D. ekstrem

15. Dalam Supervised Learning untuk use case ini, jika kita merepresentasikan data sebagai pasangan (X, y) , maka X adalah...

- A. Hanya berupa variabel hasil panen padi.
- B. Set fitur yang terdiri dari curah hujan, suhu, kelembaban, pupuk, dan luas lahan.
- C. Fungsi konstan yang memetakan hubungan linear pertanian.
- D. Nilai eror prediksi atau residu dari model regresi.

16. Persamaan regresi linear yang menambahkan fitur kuadratik untuk menangkap pola non-linear dituliskan sebagai:

$$\hat{y} = \beta_0 + \beta_1 \cdot \text{rainfall} + \beta_2 \cdot \text{rainfall}^2 + \dots$$

Mengapa model ini masih dikategorikan sebagai model "regresi linear"?

- A. Karena hasil prediksinya ($\hat{y}$) selalu membentuk garis lurus yang linear di atas grafik.
- B. Karena model tersebut tetap bersifat linear terhadap parameter-parameter koefisiennya (β)

).

C. Karena variabel bebasnya tidak mengalami operasi perkalian dengan variabel bebas lainnya.

D. Karena model tersebut tidak mampu mendeteksi adanya interaksi non-linear dalam data asli.

17. Metrik evaluasi Supervised Learning yang mengukur rata-rata selisih absolut antara nilai aktual dengan nilai prediksi tanpa mempertimbangkan arah error disebut...

A. Mean Absolute Error (MAE)

B. Root Mean Squared Error (RMSE)

C. Coefficient of Determination (R^2)

D. Within-Cluster Sum of Squares (WCSS)

18. Formula matematika untuk menghitung Root Mean Squared Error (RMSE) adalah...

A. $RMSE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$

B. $RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$

C. $RMSE = 1 - \frac{SS_{res}}{SS_{tot}}$

D. $RMSE = \sum_{k=1}^K \sum_{x_i \in C_k} ||x_i - \mu_k||^2$

19. Apa interpretasi yang paling tepat dari nilai Koefisien Determinasi (R^2) yang mendekati 1 dalam evaluasi model prediksi hasil panen?

A. Model memiliki tingkat kesalahan absolut (MAE) yang sangat tinggi.

B. Variasi pada variabel target (hasil panen) dapat dijelaskan dengan sangat baik oleh fitur-fitur dalam model.

C. Model mengalami kegagalan fungsi akibat adanya pencilan yang signifikan.

D. Distribusi data target bersifat sangat miring (*highly skewed*).

20. Pada grafik *Actual vs Predicted*, jika titik-titik data hasil prediksi tersebar sangat jauh dan tidak membentuk pola mendekati garis

diagonal, hal ini mengindikasikan...

- A. Performa prediksi model sangat baik dengan nilai kesalahan mendekati nol.
- B. Adanya korelasi linear yang sempurna antara fitur input dengan target.
- C. Model memiliki nilai kesalahan (error) yang besar dan performa prediksi yang kurang baik.
- D. Seluruh data berhasil diklasifikasikan ke dalam cluster yang tepat.

21. Pada grafik *Actual vs Predicted*, jika terdapat beberapa titik data aktual yang bernilai mendekati nol namun diprediksi jauh lebih tinggi oleh model, fenomena domain pertanian apa yang kemungkinan besar terjadi pada titik data tersebut?

- A. Lahan tersebut menggunakan varietas padi hibrida unggulan yang belum tercatat.
- B. Terjadi kasus gagal panen (*crop failure*) akibat hama atau bencana yang tidak terekam oleh fitur cuaca standar.
- C. Efisiensi penggunaan pupuk di lahan tersebut mencapai nilai maksimum optimal.
- D. Terjadi kesalahan formulasi dalam penghitungan metrik Silhouette Score.

22. Dalam Unsupervised Learning untuk segmentasi lahan, variabel manakah yang umumnya dimasukkan ke dalam fitur analisis X ?

- A. Hanya variabel hasil panen saja.
- B. Hanya variabel curah hujan dan suhu tanpa hasil panen.
- C. Variabel masukan lahan seperti curah hujan, pupuk, suhu, termasuk juga hasil panen (tanpa menetapkan target khusus).
- D. Hanya label pengelompokan biner yang dibuat secara manual oleh petani.

23. Tujuan utama dari penggunaan algoritma K-Means Clustering pada data lahan pertanian adalah...

- A. Meminimalkan jarak antar-cluster (inter-cluster distance) dan memaksimalkan jarak intra-cluster.
- B. Meminimalkan variasi jarak di dalam cluster yang sama (intra-cluster distance) dengan mengelompokkan data yang mirip.
- C. Menemukan nilai koefisien regresi optimal (β) guna memprediksi tonase panen di masa

depan.

D. Memisahkan data secara linear menggunakan hyperplane berdimensi tinggi.

24. Apa yang dimaksud dengan "centroid" dalam algoritma K-Means?

A. Batas terluar dari suatu cluster yang menentukan rentang maksimum nilai data.

B. Titik pusat geometris dari suatu cluster yang merepresentasikan rata-rata posisi seluruh data dalam cluster tersebut.

C. Nilai error terkecil yang diperoleh setelah model regresi linear mencapai konvergensi.

D. Variabel target yang memiliki korelasi paling tinggi dalam analisis multivariat.

25. Metrik evaluasi yang digunakan untuk mengukur seberapa baik suatu objek dikelompokkan dalam cluster-nya sendiri dibandingkan dengan cluster terdekat lainnya disebut...

A. Mean Absolute Error

B. Silhouette Score

C. Within-Cluster Sum of Squares

D. Coefficient of Determination

26. Dalam rumus Silhouette Score:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

Apa representasi dari simbol $a(i)$?

A. Rata-rata jarak titik i ke titik lain dalam cluster yang berbeda secara keseluruhan.

B. Rata-rata jarak titik i ke titik lain dalam cluster yang sama.

C. Rata-rata jarak dari centroid cluster satu ke centroid cluster lainnya.

D. Jarak terdekat dari titik i ke batas wilayah pencilan (*outlier*).

27. Jika hasil perhitungan Silhouette Score suatu model clustering mendekati nilai -1 , hal ini menunjukkan bahwa...

- A. Cluster terbentuk dengan sangat baik, terpisah secara jelas, dan padat.
- B. Data kemungkinan besar telah salah ditempatkan dan dimasukkan ke dalam cluster yang salah.
- C. Jumlah cluster (K) yang dipilih sudah sangat optimal sesuai dengan kaidah Elbow Method.
- D. Jarak antar-centroid cluster bernilai nol.

28. Bagaimana prinsip kerja Elbow Method dalam menentukan jumlah cluster (K) yang optimal?

- A. Memilih nilai K yang menghasilkan nilai Silhouette Score paling mendekati angka nol.
- B. Mencari titik "siku" pada grafik hubungan antara nilai K dengan WCSS, di mana penurunan WCSS mulai melambat secara signifikan.
- C. Memilih nilai K terbesar yang didukung oleh memori komputer untuk akurasi maksimal.
- D. Mencari titik potong antara kurva regresi linear dengan kurva regresi kuadratik.

29. Apa kepanjangan dan definisi dari istilah WCSS dalam konteks evaluasi clustering?

- A. *Within-Cluster Sum of Squares*, yaitu jumlah kuadrat jarak antara setiap titik data dengan centroid cluster-nya.
- B. *Weighted Cluster Standard Score*, yaitu nilai deviasi standar terbobot dari seluruh centroid.
- C. *Within-Cluster Silhouette Separation*, yaitu selisih rata-rata jarak antar-cluster yang berdekatan.
- D. *Wide Cluster Selection System*, yaitu metode pencarian otomatis untuk menentukan nilai indeks Silhouette terbaik.

30. Setelah melakukan interpretasi hasil clustering pada data lahan, ditemukan "Cluster A" memiliki karakteristik: pupuk tinggi, curah hujan sedang, namun hasil panen sangat rendah. Apa kesimpulan domain pertanian yang logis untuk kasus ini?

- A. Penggunaan pupuk yang sangat tinggi selalu merusak tanaman tanpa peduli kondisi tanah.
- B. Ada faktor pembatas lain (seperti serangan hama atau suhu ekstrem) yang membuat pemupukan masif menjadi tidak efektif.

C. Algoritma K-Means gagal mengelompokkan data secara objektif sehingga hasilnya harus diabaikan.

D. Jumlah kluster yang dipilih terlalu sedikit sehingga polanya menjadi acak.

31. Dalam model Reinforcement Learning untuk sistem irigasi otomatis, manakah yang bertindak sebagai "Environment"?

A. Algoritma pembelajaran mesin atau katup pengontrol irigasi.

B. Lahan pertanian nyata beserta seluruh dinamika tanah dan cuacanya.

C. Keputusan untuk menyiramkan air dalam jumlah tertentu.

D. Skor efisiensi air dan peningkatan hasil panen yang diperoleh.

32. Manakah dari urutan berikut yang menunjukkan pipeline machine learning end-to-end yang logis dan runtut?

A. Modeling → EDA → Data Collection → Feature Engineering → Evaluation → Deployment

B. Data Collection → Modeling → Feature Engineering → EDA → Deployment → Evaluation

C. Problem Definition → Data Collection → EDA → Feature Engineering → Modeling → Evaluation → Deployment

D. Feature Engineering → Data Collection → EDA → Evaluation → Modeling → Deployment

33. Manakah yang merupakan contoh nyata dari tahapan "Deployment" dalam konteks use case pertanian yang dibahas?

A. Membagi data historis menjadi 80% training dan 20% testing.

B. Mengintegrasikan model prediksi hasil panen ke dalam dashboard aplikasi berbasis web agar dapat diakses oleh petani.

C. Menulis kode program untuk menghitung nilai korelasi Pearson menggunakan pustaka pandas.

D. Melakukan survei langsung ke sawah untuk mengambil sampel tanah menggunakan sekop.

34. Perhatikan baris kode pembuatan data sintetis berikut:

`rain_effect = -0.0009 * (rainfall - 180)**2 + 5.5`

Berdasarkan persamaan tersebut, pada nilai curah hujan berapakah efek hujan (rain_effect) terhadap hasil panen bernilai maksimum?

- A. 0 mm
- B. 90 mm
- C. 180 mm
- D. 360 mm

35. Mengapa pada kode data sintetis di atas efek suhu (temp_effect) dirumuskan sebagai:

`temp_effect = -0.08 * (temperature - 27)**2 + 1.2`

(Catatan: perhatikan tanda minus pada koefisien -0.08)

- A. Suhu lingkungan di atas atau di bawah 27°C akan meningkatkan hasil panen secara eksponensial.
- B. Suhu optimal untuk pertumbuhan padi diasumsikan berada pada 27°C , di mana penyimpangan dari suhu tersebut akan menurunkan hasil panen.
- C. Suhu tidak memiliki pengaruh apa pun karena nilainya dikuadratkan.
- D. Suhu rata-rata lingkungan selalu bernilai konstan 27°C di seluruh wilayah Indonesia.

36. Dalam kode program berikut:

```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X_cluster)
```

Mengapa standardisasi fitur menggunakan StandardScaler sangat

penting dilakukan sebelum menjalankan algoritma K-Means Clustering?

- A. Agar seluruh variabel memiliki tipe data kategorikal yang seragam.
- B. K-Means menggunakan perhitungan jarak (seperti Euclidean distance) yang sangat sensitif terhadap perbedaan skala antarvariabel.
- C. Standardisasi digunakan untuk menghilangkan seluruh outlier secara otomatis dari dataset.
- D. Tanpa standardisasi, model K-Means tidak dapat menghasilkan nilai centroid yang stabil.

37. Jika kita membandingkan tiga paradigma ML dalam satu use case pertanian, pasangan manakah yang menyajikan hubungan tujuan dan pendekatan yang salah?

- A. Prediksi hasil panen $\rightarrow$ Supervised Learning $\rightarrow$ Nilai hasil panen (ton/ha)
- B. Segmentasi lahan $\rightarrow$ Unsupervised Learning $\rightarrow$ Kelompok/Cluster Lahan
- C. Optimasi irigasi $\rightarrow$ Reinforcement Learning $\rightarrow$ Kebijakan Aksi Penyiraman
- D. Memilih varietas unggul $\rightarrow$ Unsupervised Learning $\rightarrow$ Aturan manual bersyarat (*if-else*)

38. Pada tahapan Feature Engineering, apa tujuan utama pembuatan fitur rasio seperti jumlah pupuk dibagi luas lahan ($fertilizer_per_area$)?

- A. Mengurangi jumlah dimensi data agar proses pelatihan model berjalan lebih cepat.
- B. Menghilangkan ketergantungan semu terhadap skala mutlak, sehingga efisiensi dosis pupuk dapat dinilai secara adil terlepas dari luas lahan yang berbeda.
- C. Mengubah data kontinu menjadi data kategorikal berlabel agar regresi linear lebih stabil.
- D. Memastikan tidak ada data pupuk yang bernilai nol atau negatif dalam dataset.

39. Di bawah ini merupakan keputusan dari temuan EDA yang tercantum pada materi kuliah, kecuali...

- A. Data curah hujan miring (*skewed*) $\rightarrow$ Keputusan: Lakukan scaling atau transformasi.
- B. Relasi curah hujan dan hasil non-linear $\rightarrow$ Keputusan: Tambahkan fitur kuadrat.

C. Adanya outlier hasil panen mendekati nol → Keputusan: Langsung menghapus outlier dari dataset tanpa analisis domain.

D. Ditemukan fitur yang korelasinya lemah → Keputusan: Lakukan pemilihan fitur (*feature selection*).

40. Model regresi linear mengevaluasi kinerjanya menggunakan data uji. Jika nilai MAE bernilai 0.5 dan rata-rata hasil panen aktual adalah 5.0 ton/ha , bagaimana menginterpretasikan kesalahan tersebut secara praktis?

A. Rata-rata prediksi model meleset sekitar 0.5 ton/ha (atau sekitar 10%) dari hasil panen yang sebenarnya.

B. Model dipastikan salah dalam memprediksi sebanyak 50% dari total seluruh sampel data yang ada.

C. Model hanya mampu memprediksi dengan benar jika hasil panen aktual bernilai tepat 0.5 ton/ha .

D. Kesalahan prediksi model selalu bernilai konstan sebesar 0.5 ton/ha di setiap titik data.

41. Metode manakah yang digunakan untuk membagi variabel kontinu curah hujan menjadi kategori diskrit seperti "rendah", "sedang", dan "tinggi" dalam Python Pandas?

A. `pd.concat()`

B. `pd.cut()`

C. `pd.groupby()`

D. `pd.merge()`

42. Salah satu masalah dalam analisis data pertanian adalah multikolinieritas (hubungan linear yang kuat antarfitur input). Tahapan pipeline ML mana yang paling tepat digunakan untuk mengidentifikasi dan menangani masalah ini sejak awal?

A. Problem Definition

B. Data Collection

C. EDA dan Feature Engineering

D. Model Deployment

43. Dalam algoritma K-Means, jika kita menentukan jumlah cluster $K = 1$, apa yang akan terjadi pada perhitungan WCSS?

A. Nilai WCSS akan bernilai minimum atau sama dengan nol.

B. Nilai WCSS akan mencapai nilai maksimum karena seluruh titik data dihitung jaraknya terhadap satu centroid tunggal global.

C. Nilai WCSS tidak dapat didefinisikan karena pembagian dengan nol pada rumus Silhouette Score.

D. Nilai WCSS akan konvergen secara instan ke nilai rata-rata Silhouette Score.

44. Manakah pernyataan berikut yang paling tepat mengenai hubungan antara performa model regresi dengan kompleksitas fitur yang ditambahkan (seperti menambahkan fitur polinomial pangkat tinggi)?

A. Menambahkan fitur pangkat tinggi tanpa batas selalu menjamin model memiliki akurasi yang stabil pada data baru.

B. Menambahkan terlalu banyak fitur kompleks berisiko menyebabkan *overfitting*, di mana model bekerja sangat baik pada data latihan tetapi buruk pada data baru.

C. Regresi linear tidak akan terpengaruh sama sekali oleh jumlah fitur karena koefisiennya otomatis bernilai nol.

D. Penambahan fitur kompleks akan menurunkan nilai R^2 pada data latihan secara drastis.

45. Dalam algoritma K-Means Clustering, penentuan posisi awal centroid dilakukan secara acak. Konsekuensi dari hal ini adalah...

A. Hasil pengelompokkan (cluster) dipastikan akan selalu sama persis di setiap kali program dijalankan.

B. Algoritma K-Means mungkin menghasilkan pengelompokkan yang sedikit berbeda di setiap proses jalannya program (*local optima*), kecuali jika ditentukan parameter `random_state`.

C. Waktu komputasi algoritma akan menjadi tidak terbatas karena centroid terus berputar.

D. Nilai Silhouette Score akan selalu bernilai negatif pada iterasi pertama.

46. Dalam evaluasi model supervised, apa perbedaan mendasar antara metrik MAE dan RMSE dalam menanggapi kesalahan prediksi (error) yang besar?

A. MAE memberikan penalti yang lebih berat pada error yang besar dibandingkan RMSE karena menggunakan operasi absolut.

B. RMSE memberikan penalti yang lebih berat pada error yang besar karena mengkuadratkan selisih sebelum merata-ratakannya.

C. MAE dan RMSE selalu menghasilkan nilai numerik yang persis sama untuk setiap dataset yang dievaluasi.

D. RMSE hanya digunakan jika data berdistribusi normal, sedangkan MAE digunakan jika data miring (*skewed*).

47. Berdasarkan tabel korelasi, variabel luas lahan memiliki hubungan korelasi yang sangat kuat dengan total pupuk yang diberikan secara keseluruhan, namun korelasi terhadap produktivitas hasil panen per hektar (ton/ha) cukup rendah. Apa makna fisis dari fenomena ini?

A. Lahan yang lebih luas membutuhkan pemupukan total yang lebih banyak, tetapi produktivitas per hektar tidak semata-mata meningkat hanya karena lahannya luas.

B. Petani di lahan luas selalu memberikan pupuk secara tidak efisien sehingga merusak kualitas tanah.

C. Variabel luas lahan harus dihapus dari database karena datanya tidak valid.

D. Pupuk tidak memiliki pengaruh apa pun terhadap produktivitas padi di lahan sempit.

48. Di bawah ini adalah pustaka (*library*) Python yang diimpor pada kode program Kuliah 10 untuk melakukan pemodelan regresi linear, kecuali...

A. `sklearn.linear_model.LinearRegression`

B. `sklearn.metrics.mean_absolute_error`

C. `sklearn.metrics.mean_squared_error`

D. `sklearn.neighbors.KNeighborsClassifier`

49. Evaluasi model Unsupervised Learning lebih menantang daripada

Supervised Learning karena...

- A. Algoritma unsupervised tidak memerlukan komputasi matriks jarak.
- B. Tidak ada label target atau "kebenaran mutlak" (*ground truth*) di dalam data untuk membandingkan hasil pengelompokkan secara langsung.
- C. Nilai error pada unsupervised learning selalu bernilai tak terhingga.
- D. Unsupervised learning hanya dapat memproses data teks dan gambar, bukan data numerik kontinu.

50. Mengapa nilai evaluasi akhir dari model machine learning tidak boleh menjadi satu-satunya indikator kesuksesan dalam proyek Data Science?

- A. Karena akurasi tinggi pada data latihan tidak menjamin model tersebut berguna atau dapat diinterpretasikan untuk mendukung pengambilan keputusan nyata (*deployment*).
- B. Karena metrik seperti MAE dan Silhouette Score tidak diakui secara ilmiah dalam komunitas akademik.
- C. Karena model machine learning akan otomatis kedaluwarsa dalam waktu satu minggu setelah dibuat.
- D. Karena proses komputasi evaluasi model memakan terlalu banyak kuota internet pengguna.

Bagian II: Kunci Jawaban dan Pembahasan

Berikut adalah kunci jawaban lengkap beserta penjelasan fisis dan matematis yang singkat namun mendalam untuk masing-masing soal.

No	Kunci	Pembahasan Singkat
1	B	Hubungan nyata variabel pertanian dipengaruhi banyak faktor interaktif dan bersifat non-linear (misal: banjir akibat kelebihan hujan justru merusak tanaman), sehingga tidak bisa dimodelkan dengan aturan sederhana.
2	B	Unsupervised learning

		digunakan saat kita hanya memiliki data masukan (X) tanpa adanya label target atau "kebenaran" (y) yang ingin diprediksi.
3	C	Reinforcement learning didasarkan pada interaksi bertahap agen dengan lingkungan melalui aksi (<i>action</i>) dan penerimaan umpan balik (<i>reward</i>).
4	B	Target (y) yang ingin diprediksi dan dipahami faktor-faktor pengaruhnya adalah produktivitas padi (hasil panen dalam satuan <i>ton/ha</i>).
5	C	EDA adalah fondasi untuk mengenali karakteristik data; tanpa EDA kita berisiko melatih model menggunakan data rusak, mengabaikan non-linearitas, atau merusak prediksi karena outlier.
6	B	Data yang condong/miring (<i>skewed</i>) perlu distabilkan distribusinya menggunakan penskalaan (<i>scaling</i>) atau transformasi (misalnya transformasi logaritma) agar model bekerja optimal.
7	B	Dengan menambahkan fitur kuadrat ($rainfall^2$),

		model regresi linear parametrik dapat menangkap hubungan lengkung (parabola) tanpa kehilangan sifat linearitas parameternya.
8	C	Pencilan tidak selalu salah. Hasil panen mendekati nol bisa jadi representasi nyata kasus gagal panen (<i>crop failure</i>), sehingga interpretasi domain ahli sangat diperlukan sebelum menghapus data.
9	B	Analisis korelasi memberikan gambaran awal seberapa kuat hubungan linear antarfitur dengan target, mempermudah eliminasi fitur yang tidak relevan (<i>feature selection</i>).
10	B	Fitur dengan korelasi yang teramat sangat lemah terhadap target sebaiknya dieliminasi agar model menjadi lebih sederhana, menghindari <i>noise</i> , dan mencegah <i>overfitting</i> .
11	B	<i>Feature engineering</i> adalah proses manipulasi, transformasi, atau pembuatan fitur baru berdasarkan pemahaman ranah aplikasi (<i>domain knowledge</i>).
12	B	Efisiensi penggunaan pupuk diperoleh dengan membagi

		dosis total pupuk yang diberikan dengan luas lahan tanam ($\text{fertilizer/land_area}$).
13	A	Nilai 135 berada dalam rentang interval $(-\infty, 140]$, sehingga berdasarkan parameter binomial dikategorikan sebagai "rendah".
14	B	Nilai 180 berada dalam interval $(140, 220]$, sehingga diklasifikasikan sebagai kategori curah hujan "sedang".
15	B	Dalam supervised learning, X merepresentasikan matriks fitur input yang berisi semua variabel bebas (curah hujan, suhu, kelembaban, pupuk, luas lahan).
16	B	Istilah "linear" pada regresi linear mengacu pada hubungan fungsional yang linear terhadap parameter koefisiennya (β), bukan terhadap variabel independennya (x).
17	A	Mean Absolute Error (MAE) mengukur rata-rata selisih absolut antara nilai prediksi dan aktual: $\frac{1}{n} \sum$

18	B	RMSE dihitung dengan menguadratkan selisih prediksi, merata-ratakannya, lalu menarik akar kuadratnya. Persamaan yang benar ditunjukkan opsi B.
19	B	Nilai $R^2 \approx$ menunjukkan bahwa sebagian besar (mendekati 100%) variabilitas dari variabel target dapat dijelaskan secara linear oleh fitur-fitur di dalam model.
20	C	Pada grafik ini, kedekatan titik dengan garis diagonal $y =$ menandakan akurasi. Jika titik-titik menyebar jauh, berarti error prediksi model tersebut besar.
21	B	Gagal panen akibat faktor non-cuaca (seperti serangan hama masif) menghasilkan output riil mendekati nol, namun model memprediksinya tinggi karena fitur cuacanya normal.
22	C	Untuk segmentasi lahan tanpa target spesifik, seluruh variabel karakteristik (termasuk hasil panen) dimasukkan sebagai fitur input X agar pola kemiripan alami terbentuk.

23	B	Tujuan K-Means adalah meminimalkan variansi dalam satu cluster (meminimalkan <i>Within-Cluster Sum of Squares / WCSS</i>) agar data di dalam cluster yang sama sangat mirip.
24	B	Centroid adalah koordinat rata-rata (pusat massa) dari semua titik data yang berada di dalam cluster tersebut.
25	B	Silhouette Score digunakan untuk mengukur kualitas klusterisasi dengan membandingkan kedekatan internal objek terhadap cluster tetangga terdekatnya.
26	B	Nilai $a(i)$ merepresentasikan rata-rata jarak intra-cluster (jarak dari titik i ke seluruh titik lain di dalam cluster yang sama).
27	B	Nilai Silhouette Score yang mendekati -1 mengindikasikan bahwa rata-rata jarak ke cluster tetangga ($b(i)$) lebih kecil daripada jarak intra-cluster ($a(i)$), yang berarti salah pengelompokan.
28	B	Elbow Method mencari titik

		di mana penambahan nilai K tidak lagi memberikan penurunan WCSS secara signifikan (membentuk sudut siku).
29	A	WCSS singkatan dari <i>Within-Cluster Sum of Squares</i>, yaitu metrik jumlah kuadrat jarak antara objek data ke masing-masing centroid-nya.
30	B	Pupuk melimpah dengan cuaca ideal namun hasil panen rendah menunjukkan adanya anomali atau variabel luar pembatas (misal: serangan hama tanaman atau kerusakan tanah).
31	B	Dalam reinforcement learning, lahan pertanian nyata bertindak sebagai "Environment" tempat agen ("Sistem irigasi") bertindak dan mengamati umpan balik.
32	C	Pipeline ML yang logis dimulai dari definisi masalah → pengumpulan data → EDA → rekayasa fitur → pemodelan → evaluasi → penerapan (<i>deployment</i>).
33	B	<i>Deployment</i> adalah proses integrasi model ke dalam lingkungan produksi nyata (seperti web dashboard)

		agar dapat dimanfaatkan langsung oleh pengguna akhir (petani).
34	C	Fungsi kuadrat $-0.0009 * (rainfall - 5.5)^2 + 0.0018 * rainfall + 0.0009$ mencapai nilai puncak (maksimum) 5.5 ketika suhu kuadratnya bernilai 0, yaitu saat $rainfall = 5.5$.
35	B	Koefisien negatif pada fungsi kuadrat parabola terbalik menunjukkan bahwa performa akan turun jika suhu bergeser menjauhi nilai optimalnya (27°C).
36	B	K-Means menghitung jarak Euclidean. Jika salah satu fitur memiliki skala ribuan (misal: curah hujan) dan lainnya berskala satuan (misal: luas lahan), fitur skala besar akan mendominasi perhitungan jarak.
37	D	Memilih varietas unggul menggunakan aturan bersyarat manual bukanlah paradigma Machine Learning (tidak ada proses belajar dari data secara otomatis).
38	B	Fitur rasio membantu menormalkan variabel masukan sehingga kita dapat menilai tingkat

		pemupukan secara proporsional per satuan luas lahan, terlepas dari perbedaan dimensi luas lahan fisik.
39	C	Sesuai materi Kuliah 10, outlier yang memiliki makna domain tidak boleh langsung dihapus tanpa pemeriksaan terlebih dahulu karena bisa merepresentasikan kegagalan panen yang nyata.
40	A	Nilai MAE 0.5 berarti secara rata-rata, estimasi prediksi model regresi meleset sebesar $\pm 0.5 \text{ ton/ha}$ dari angka panen riil lapangan.
41	B	Fungsi <code>pd.cut()</code> dalam pustaka Pandas digunakan untuk melakukan diskretisasi atau pengelompokan data kontinu ke dalam kategori/bin tertentu.
42	C	Masalah multikolinieritas dianalisis pada tahap EDA (melalui matriks korelasi) dan diselesaikan pada tahap rekayasa fitur/pemilihan fitur (<i>feature selection</i>).
43	B	Jika hanya ada 1 cluster ($K =$), centroid-nya

		adalah rata-rata global data, sehingga nilai WCSS mencapai angka tertinggi karena mencakup seluruh variabilitas jarak data.
44	B	Terlalu banyak menambahkan fitur kuadratik, kubik, atau pangkat tinggi lainnya akan membuat model terlalu sensitif pada variasi data latih (<i>overfitting</i>).
45	B	Karena posisi awal centroid dipilih secara acak, K-Means rentan terjebak pada <i>local optima</i> yang berbeda di setiap eksekusi, kecuali nilai <code>random_state</code> dikunci.
46	B	RMSE menggunakan kuadrat selisih $(y_i - \hat{y}_i)^2$, sehingga kesalahan prediksi yang besar (outlier) akan memberikan dampak penalti yang jauh lebih signifikan pada skor akhir dibanding MAE.
47	A	Hubungan korelasi kuat antara luas lahan dan total pupuk hanyalah hubungan logistik (lahan luas tentu butuh pupuk lebih banyak), namun tidak menjamin produktivitas per hektarnya meningkat.
48	D	KNeighborsClassifier adalah algoritma klasifikasi

		(supervised) berbasis tetangga terdekat, yang tidak diimpor maupun digunakan dalam kode program studi kasus Kuliah 10.
49	B	Unsupervised learning tidak memiliki label target aktual (y) di awal, sehingga tidak ada indikator numerik mutlak untuk menyatakan apakah hasil pengelompokan tersebut benar 100%.
50	A	Sebuah model dengan akurasi matematis tinggi di laboratorium tidak ada nilainya jika tidak dapat diinterpretasikan secara domain ilmu dan tidak diimplementasikan untuk aksi nyata di lapangan.